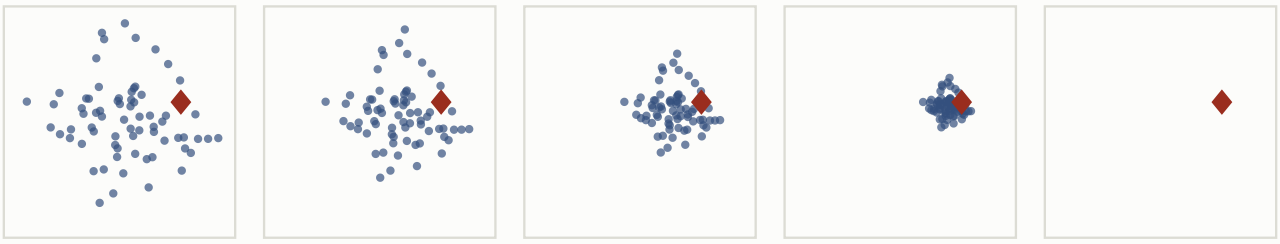
FLOW MATCHING & DIFFUSION · NOTES 02

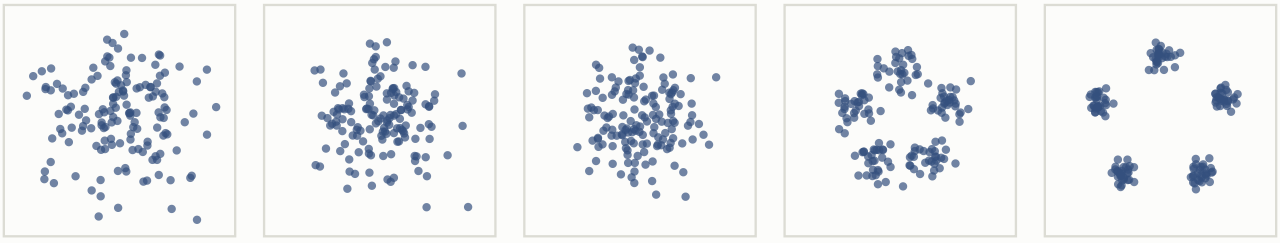
把难算的换成可算的

回归条件向量场，等价于回归边缘向量场

条件路径 $p_t(\cdot|z)$ → δ_z



边缘路径 $p_t(x)$ → p_{data}



t = 0.00　t = 0.25　t = 0.50　t = 0.75　t = 1.00

噪声 → 数据

$x = t \cdot z + (1 - t) \cdot \varepsilon$

目录

01 概率路径

1.1 训练问题的提法

1.2 概率路径与条件概率路径

1.3 边缘概率路径

1.4 高斯概率路径

02 条件向量场与边缘向量场

2.1 条件向量场

2.2 边缘化技巧

2.3 例 10：高斯概率路径对应的目标 ODE

2.4 连续性方程

2.5 定理 9 的证明

03 流匹配：学习边缘化向量场

3.1 流匹配损失

3.2 条件流匹配损失

3.3 定理 12 的直接证明

3.4 训练流程

3.5 例 13：高斯条件概率路径下的流匹配

3.6 小结 14：流匹配

流匹配：回归一个看不见的向量场

读完能写出高斯 CondOT 路径下的训练算法，并复述定理 9 与定理 12 的证明思路

课程： MIT 6.S184 Flow Matching & Diffusion Models　类型： 个人学习笔记　日期： 2026-10

上一讲把 Flow 模型写成“ODE 加神经网络向量场”，却没有说参数 θ 怎么训练。本讲回答这个问题：先构造概率路径与目标向量场，再把难以计算的边缘向量场，换成一个可以直接回归的条件向量场——这就是流匹配。

三句话读懂本讲

1. 流匹配要学的是边缘向量场：沿着它走的 ODE 能把初始分布变成数据分布；但它含有难以求解的积分，不能直接拿来回归。
2. 边缘化技巧（定理 9）：边缘向量场是各条件向量场按后验概率加权的平均；条件向量场有解析表达式，高斯路径下是闭式。
3. 定理 12：回归条件向量场的损失与回归边缘向量场的损失只差一个与 θ 无关的常数，梯度相同；因此训练无需仿真 ODE，只是一个简单的回归。

01. 概率路径

1.1. 训练问题的提法

在上一节中，我们将流模型与扩散模型构建为由神经网络向量场 $\boldsymbol{u}_{\theta,t}$ 参数化的生成模型。但尚未讨论模型的训练方法：即如何优化参数 θ，让生成模型输出合理结果，例如高质量图像或生动视频。接下来我们介绍流匹配（**flow matching**）[25, 1, 27]，这是一套用于训练 $\boldsymbol{u}_{\theta,t}$ 的算法，具备简洁、可扩展的特点，代表当前最优技术水平。

本节我们仅讨论流模型：模型包含神经网络 $\boldsymbol{u}_{\theta,t}$，通过对常微分方程（ODE）

$$X_0 \sim p_{\text{init}}, \quad dX_t = \boldsymbol{u}_{\theta,t}(X_t)\, dt \tag{10}$$

进行数值模拟得到生成样本，并取 $t=1$ 时刻的终点 X_1 作为输出样本。正如前文所述，我们的目标是使 X_1 服从数据分布 p_{data}，也就是 $X_1 \sim p_{\text{data}}$。因此，神经网络“如何训练”本质上是这样一个问题：我们该如何优化参数 θ，使得对式 (10) 的流模型做模拟后，得到的样本 X_1 服从数据分布 p_{data}？

1.2. 概率路径与条件概率路径

流匹配的第一步是定义**概率路径（probability path）**。直观来说，概率路径刻画了噪声分布 p_{init} 与数据分布 p_{data} 之间的渐进插值过程（见图 4）。我们为什么需要这样的插值？回顾前面，我们期望的常微分方程轨迹满足：$t=0$ 时 $X_0 \sim p_{\text{init}}$，$t=1$ 时 $X_1 \sim p_{\text{data}}$。但在起点和终点之间，也就是 $0<t<1$ 的时刻，过程应当如何演化？实际上，中间阶段的演化形式存在一定选择自由度，而概率路径正是对这一过程的数学形式化表达。

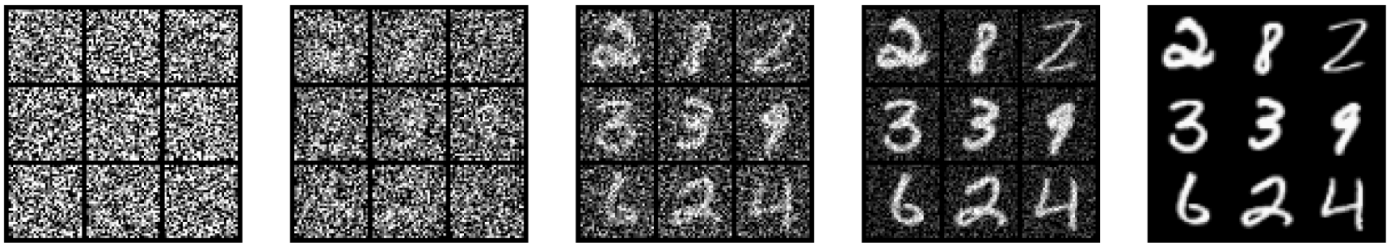


Figure 4: Gradual interpolation from noise to data via a Gaussian conditional probability path for a collection of images. Note that each image is a data point of dimension $d = 32 \times 32$, so we are plotting individual samples from the probability path, while in Figure 5 we plot the distribution as a 2d histogram.

图 4. 高斯条件概率路径上，一组图像从噪声逐步插值到数据。每张图像是一个 d = 32 × 32 维的数据点，这里画的是概率路径上的单个样本；图 5 则以二维直方图画整个分布。 · 来源：MIT 6.S184 讲义

下文针对数据点 $z \in \mathbb{R}^d$，用 δ_z 表示狄拉克 δ“分布”。它是最简单的一类分布：从 δ_z 中采样永远得到 z（即确定性采样）。**条件（插值）概率路径**是定义在 $\mathbb{R}^d$ 上的一族分布 $p_t(x|z)$，满足：

$$p_0(\cdot|z) = p_{\text{init}}, \quad p_1(\cdot|z) = \delta_z, \quad \forall z \in \mathbb{R}^d \tag{11}$$

换言之，条件概率路径会将初始分布 p_{init} 逐步变换为单个数据点（参见图 4）。你可以把概率路径理解为分布空间中的一条轨迹。

1.3. 边缘概率路径

每一条条件概率路径 $p_t(x|z)$ 都可以导出一条**边缘概率路径**（marginal probability path）$p_t(x)$：先从数据分布中采样数据点 $z \sim p_{\text{data}}$，再从 $p_t(\cdot|z)$ 中采样，得到的分布即为边缘概率路径。

$$z \sim p_{\text{data}},\ x \sim p_t(\cdot|z) \implies x \sim p_t \qquad \blacktriangleright \text{从边缘路径采样} \tag{12}$$

$$p_t(x) = \int p_t(x|z)\, p_{\text{data}}(z)\, dz \qquad \blacktriangleright \text{边缘路径的概率密度} \tag{13}$$

注意：我们可以按式 (12) 完成采样，但无法直接得到密度 $p_t(x)$ 的数值，因为该积分难以求解（也就是式 (12) 可计算，式 (13) 不可计算）。读者可以自行验证：由式 (11) 中 $p_t(\cdot|z)$ 的约束条件，边缘概率路径 p_t 恰好完成从 p_{init} 到 p_{data} 的插值：

$$p_0 = p_{\text{init}},\quad p_1 = p_{\text{data}} \qquad \blacktriangleright \text{噪声-数据插值} \tag{14}$$

概率路径中**最重要的一类例子是高斯概率路径**。

例 8 · 高斯条件概率路径

高斯概率路径是一种应用十分广泛的概率路径，当前绝大多数 SOTA 模型都采用该路径。设 α_t, β_t 为 noise schedulers（噪声调度函数）：两个连续可微的单调函数，满足 $\alpha_0 = \beta_1 = 0$，$\alpha_1 = \beta_0 = 1$。我们定义条件概率路径：

$$p_t(\cdot|z) = \mathcal{N}\left(\alpha_t z,\ \beta_t^2 \boldsymbol{I}_d\right) \qquad \blacktriangleright \text{高斯条件路径} \tag{15}$$

由 α_t, β_t 的约束条件可得：

$$p_0(\cdot|z) = \mathcal{N}\left(\alpha_0 z, \beta_0^2 \boldsymbol{I}_d\right) = \mathcal{N}(0, \boldsymbol{I}_d), \quad p_1(\cdot|z) = \mathcal{N}\left(\alpha_1 z, \beta_1^2 \boldsymbol{I}_d\right) = \delta_z$$

这里用到一个性质：均值为 z、方差为 0 的正态分布等价于狄拉克 δ 分布 δ_z。因此，当取初始分布 $p_{\text{init}} = \mathcal{N}(0, \boldsymbol{I}_d)$ 时，该 $p_t(x|z)$ 满足式 (11)，是一条合法的条件插值路径。图 4 展示了它在图像上的应用。

我们可以把从边缘路径 p_t 的采样过程写成：

$$\begin{gathered} z \sim p_{\text{data}},\ \varepsilon \sim p_{\text{init}} = \mathcal{N}(0, \boldsymbol{I}_d) \implies \\ x = \alpha_t z + \beta_t \varepsilon \sim p_t \qquad \blacktriangleright \text{高斯边缘路径采样} \end{gathered} \tag{16}$$

直观理解：t 越小，该过程叠加的噪声越多；到 $t = 0$ 时刻，样本只剩下纯噪声。图 5 绘制了这类插值路径的示例。

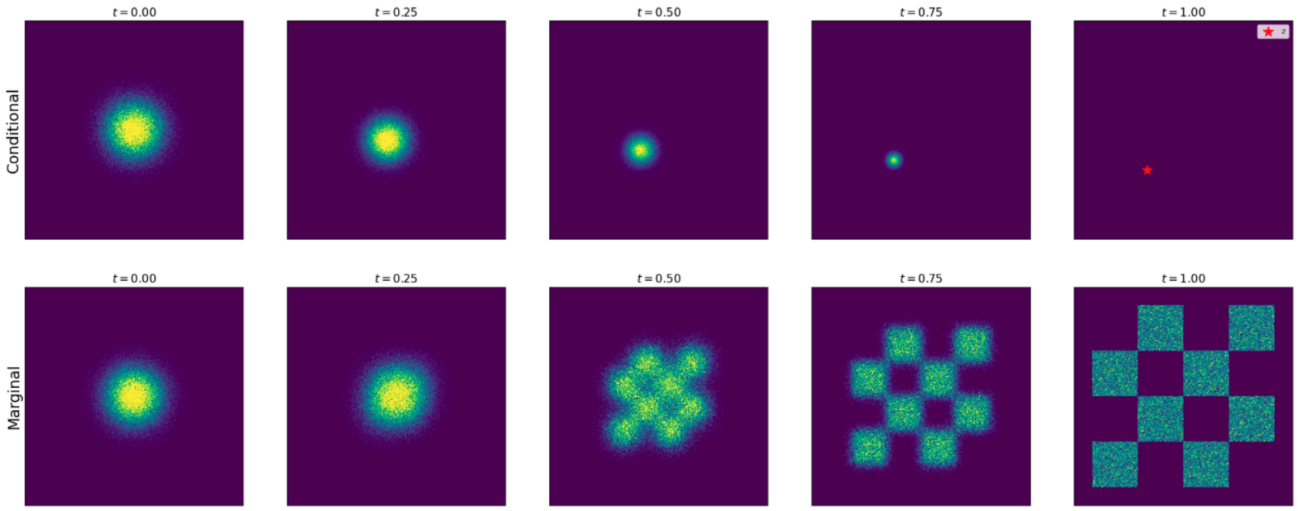
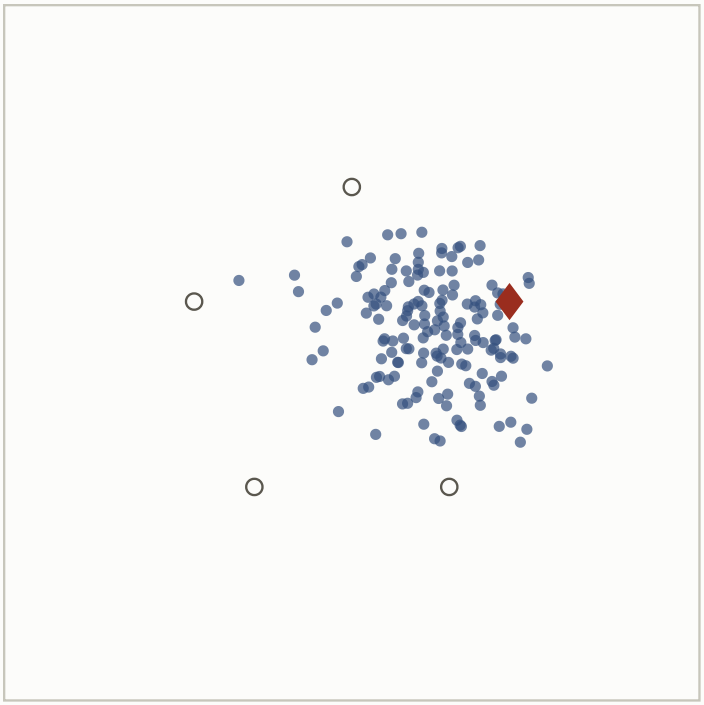


Figure 5: Illustration of a conditional (top) and marginal (bottom) probability path. Here, we plot a Gaussian probability path with $\alpha_t = t, \beta_t = 1 - t$. The conditional probability path interpolates a Gaussian $p_{\text{init}} = \mathcal{N}(0, I_d)$ and $p_{\text{data}} = \delta_z$ for single data point z. The marginal probability path interpolates a Gaussian and a data distribution p_{data} (Here, p_{data} is a toy distribution in dimension $d = 2$ represented by a chess board pattern.)

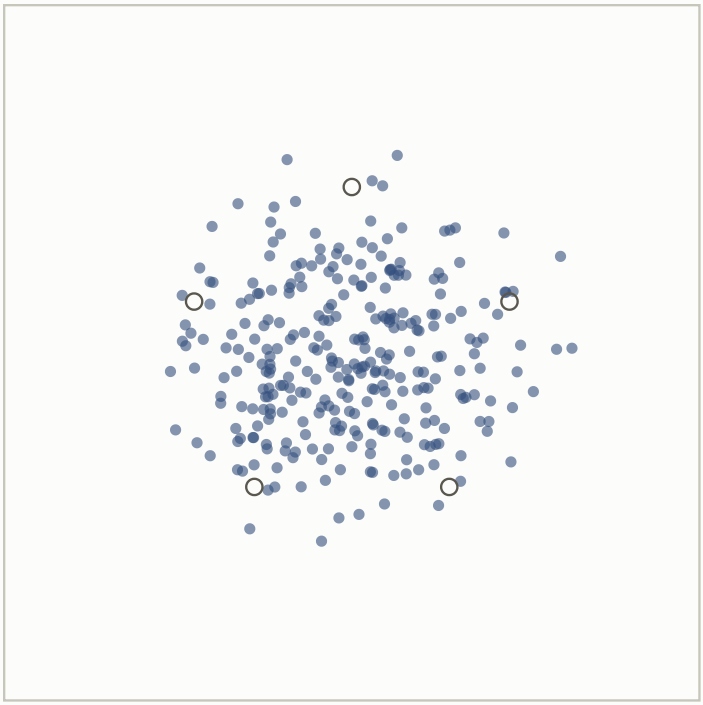
图 5. 条件（上）与边缘（下）概率路径示意，取高斯路径 $\alpha_t = t$，$\beta_t = 1 - t$。条件概率路径把标准高斯插值到单个数据点 z 的狄拉克分布；边缘概率路径把标准高斯插值到数据分布（这里是二维棋盘格玩具分布）。· 来源：MIT 6.S184 讲义

图 5 是静态的五帧。下面的交互图用同一组公式让你自己拖动时间：每个样本都由式 (16) 直接算出，点沿着从噪声 ε 到数据 z 的直线匀速移动（此处 $\alpha_t = t$, $\beta_t = 1 - t$）。

条件路径：固定数据点 z_2



边缘路径：先从数据分布抽 z，再从 $p_t(\cdot|z)$ 抽 x



时间 t = **0.50**　α_t = 0.50，β_t = 0.50

条件路径图选定的数据点：　z_1　z_2　z_3　z_4　z_5

图例：空心圆为五个数据簇的中心；红色菱形为条件路径图选定的数据点 z。

0 < t < 1：条件路径图是 N(0.50·z, 0.50²·I)，边缘路径图先随机抽 z 再抽 x，整体分布介于高斯与数据分布之间。

✦ 交互图 A · 条件路径与边缘路径（α_t = t，β_t = 1 − t）。拖动 t：左图固定一个数据点 z，样本 x = t·z + (1−t)·ε 随 t 增大收缩到 z；右图先从五个数据簇中随机抽 z 再抽 x，样本的整体分布从标准高斯过渡到数据分布（窄屏下两图上下排列，左图即上方）。

02. 条件向量场与边缘向量场

概率路径 $\{p_t\}_{0\le t\le 1}$ 规定了轨迹上点 X_t 应当服从的分布 $X_t \sim p_t$。到目前为止，这还只是我们期望满足的性质。但我们如何找到一个向量场，使得轨迹 X_t 能够沿着该概率路径演化？流匹配方法显式构造出这样一类向量场——**边缘向量场**，本节将对此展开说明。

2.1. 条件向量场

对任意数据点 $z \in \mathbb{R}^d$，记 $\boldsymbol{u}_t^{\text{target}}(\cdot|z)$ 为**条件向量场**。该向量场需要满足：由其对应的常微分方程能够生成条件概率路径 $p_t(\cdot|z)$，即

$$X_0 \sim p_{\text{init}}, \quad \frac{d}{dt} X_t = \boldsymbol{u}_t^{\text{target}}(X_t|z) \\ \implies X_t \sim p_t(\cdot|z), \quad (0 \le t \le 1). \tag{17}$$

我们通常可以通过手工代数推导，解析求出条件向量场 $\boldsymbol{u}_t^{\text{target}}(\cdot|z)$。我们将在例 10 中，针对前面一直使用的高斯概率路径，推导对应的条件向量场 $\boldsymbol{u}_t(x|z)$，以此演示该过程。

乍一看，条件向量场似乎没有实用价值：该常微分方程的终点 X_1 会收敛到 $X_1 = z$，也就是仅仅重现已知的数据点 z。但条件向量场是构造另一个向量场的基础，这个向量场可以直接生成服从 p_{data} 的真实样本：

2.2. 边缘化技巧

定理 9 · 边缘化技巧

设 $\boldsymbol{u}_t^{\text{target}}(x|z)$ 为式 (17) 定义的条件向量场。定义边缘向量场 $\boldsymbol{u}_t^{\text{target}}(x)$：

$$\boldsymbol{u}_t^{\text{target}}(x) = \int \boldsymbol{u}_t^{\text{target}}(x|z) \, \frac{p_t(x|z) \, p_{\text{data}}(z)}{p_t(x)} \, dz \tag{18}$$

该边缘向量场将沿着边缘概率路径演化，即：

$$X_0 \sim p_{\text{init}}, \quad \frac{d}{dt} X_t = \boldsymbol{u}_t^{\text{target}}(X_t) \\ \implies X_t \sim p_t, \quad (0 \le t \le 1). \tag{19}$$

特别地，该常微分方程满足 $X_1 \sim p_{\text{data}}$。因此可以说：**$\boldsymbol{u}_t^{\text{target}}$ 将噪声分布 p_{init} 转化为数据分布 p_{data}**。

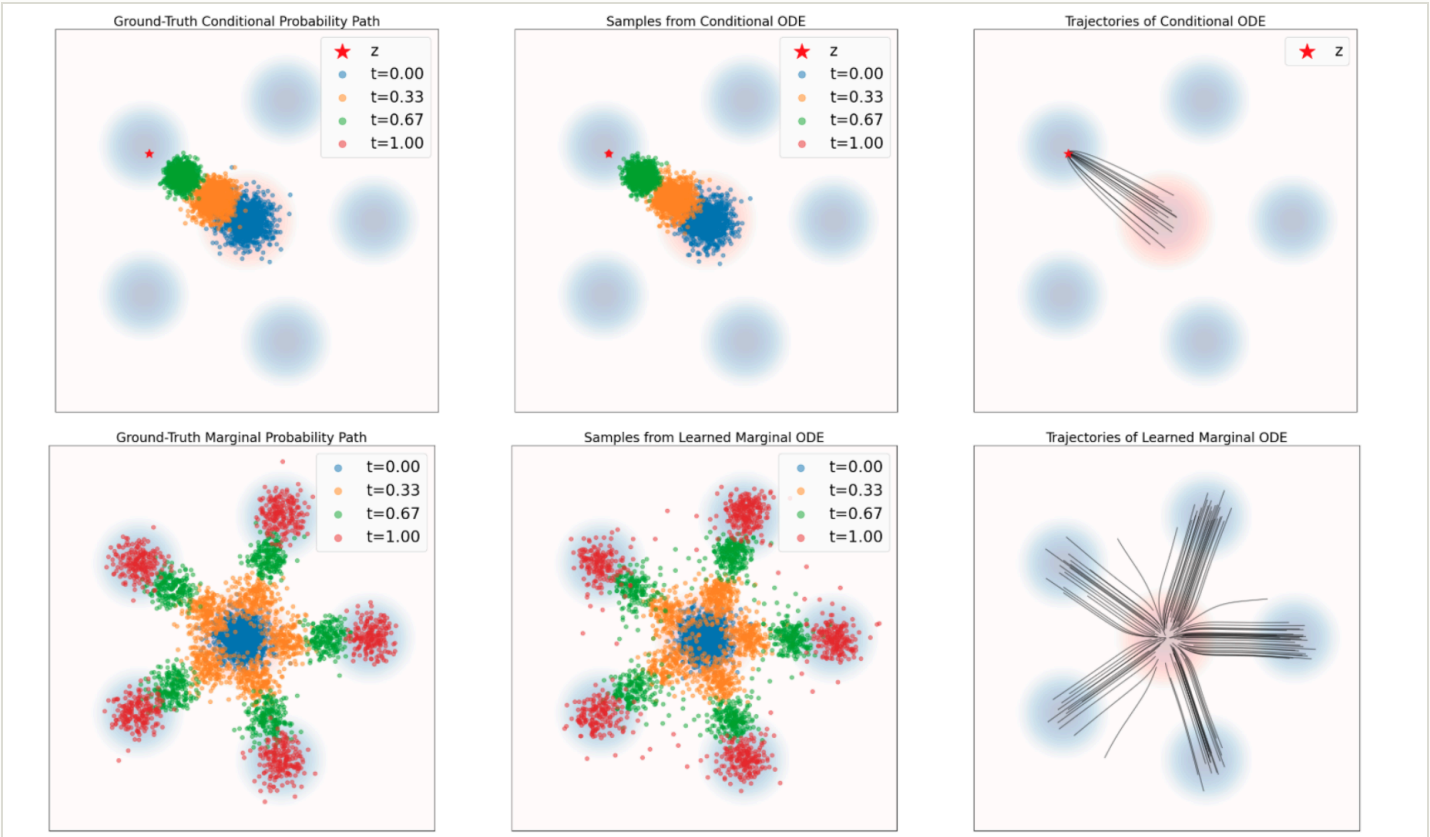


Figure 6: Illustration of Theorem 9. Simulating a probability path with ODEs. Data distribution p_{data} in blue background. Gaussian p_{init} in red background. Top row: Conditional probability path. Left: Ground truth samples from conditional path $p_t(\cdot|z)$. Middle: ODE samples over time. Right: Trajectories by simulating ODE with $u_t^{\text{target}}(x|z)$ in Equation (20). Bottom row: Simulating a marginal probability path. Left: Ground truth samples from p_t. Middle: ODE samples over time. Right: Trajectories by simulating ODE with marginal vector field $u_t^{\text{flow}}(x)$. As one can see, the conditional vector field follows the conditional probability path and the marginal vector field follows the marginal probability path.

图 6. 定理 9 图示：用 ODE 模拟概率路径。蓝色背景为数据分布，红色背景为初始高斯分布。上排为条件概率路径：左为条件路径的真值样本，中为随时间演化的 ODE 样本，右为按式 (20) 的条件向量场仿真 ODE 得到的轨迹；下排为边缘概率路径：左为边缘路径的真值样本，中为 ODE 样本，右为按边缘向量场仿真 ODE 得到的轨迹。可以看到，条件向量场沿着条件概率路径演化，边缘向量场沿着边缘概率路径演化。 · 来源：MIT 6.S184 讲义

2.3. 例 10：高斯概率路径对应的目标 ODE

例 10 · 高斯概率路径对应的目标常微分方程

沿用前文设定：噪声调度函数 α_t, β_t 满足 $p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 \boldsymbol{I}_d)$（见式 (15)）。记 $\dot{\alpha}_t = \partial_t \alpha_t$、$\dot{\beta}_t = \partial_t \beta_t$ 分别为 α_t 和 β_t 对时间的导数。我们将证明，如下高斯条件向量场

$$\boldsymbol{u}_t^{\text{target}}(x|z) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) z + \frac{\dot{\beta}_t}{\beta_t} x \tag{20}$$

是满足定理 9 定义的合法条件向量场：若初始值 $X_0 \sim \mathcal{N}(0, \boldsymbol{I}_d)$，则该向量场对应的 ODE 轨迹 X_t 满足 $X_t \sim p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 \boldsymbol{I}_d)$。图 6 从可视化角度验证这一点：将条件概率路径采样（真值）与该流 ODE 仿真轨迹采样对比，可以看到二者分布一致。下面给出证明。

证明：首先构造条件流映射 $\psi_t^{\text{target}}(x|z)$

$$\psi_t^{\text{target}}(x|z) = \alpha_t z + \beta_t x \tag{21}$$

若 X_t 是 $\psi_t^{\text{target}}(\cdot|z)$ 对应的 ODE 轨迹，且 $X_0 \sim p_{\text{init}} = \mathcal{N}(0, \boldsymbol{I}_d)$，则由定义：

$$X_t = \psi_t^{\text{target}}(X_0|z) = \alpha_t z + \beta_t X_0 \sim \mathcal{N}(\alpha_t z, \beta_t^2 \boldsymbol{I}_d) = p_t(\cdot|z).$$

由此可知该轨迹服从条件概率路径分布（即满足式 (17)）。接下来需要从 $\psi_t^{\text{target}}(x|z)$ 中提取向量场 $\boldsymbol{u}_t^{\text{target}}(x|z)$。根据流的定义（式 (2b)），对任意 $x, z \in \mathbb{R}^d$，有

$$\begin{aligned}
& \frac{d}{dt} \psi_t^{\text{target}}(x|z) = \boldsymbol{u}_t^{\text{target}}\left(\psi_t^{\text{target}}(x|z) \,\middle|\, z\right) && \text{(i)} \\
\iff\ & \dot{\alpha}_t z + \dot{\beta}_t x = \boldsymbol{u}_t^{\text{target}}(\alpha_t z + \beta_t x \mid z) && \text{(ii)} \\
\iff\ & \dot{\alpha}_t z + \dot{\beta}_t \left(\frac{x - \alpha_t z}{\beta_t} \right) = \boldsymbol{u}_t^{\text{target}}(x \mid z) && \text{(iii)} \\
\iff\ & \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) z + \frac{\dot{\beta}_t}{\beta_t} x = \boldsymbol{u}_t^{\text{target}}(x \mid z)
\end{aligned}$$

式 (i) 用到 $\psi_t^{\text{target}}(x|z)$ 的定义（式 (21)）；式 (ii) 做变量替换 $x \to (x - \alpha_t z)/\beta_t$；式 (iii) 仅做代数化简。上式正是式 (20) 定义的高斯条件向量场。命题得证。

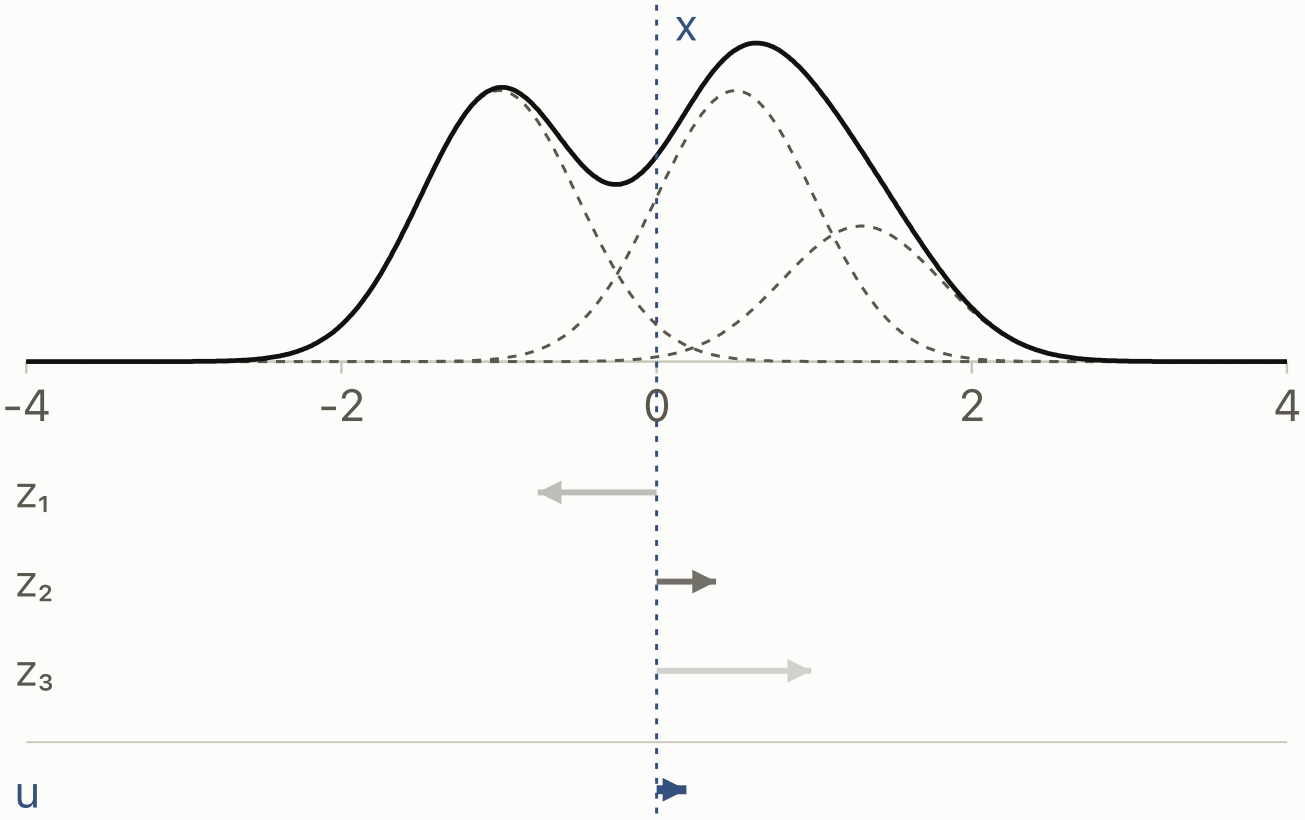
也可以将该向量场代入本节后续介绍的连续性方程，再次核验结果。

定理 9 的图示参见图 6。下面我们直观理解边缘向量场。统计学中的贝叶斯公式告诉我们，如下表达式代表后验分布：

$$\frac{p_t(x|z)\,p_{\text{data}}(z)}{p_t(x)} = \text{“给定含噪样本 } x\text{，关于数据点 } z \text{ 的后验分布”}$$

其中 $p_{\text{data}}(z)$ 为先验分布。此时边缘向量场本质上就是一种加权平均：对每一个可能的数据点 z，取速度向量 $\boldsymbol{u}_t(x|z)$（也就是引导轨迹走向 z 的方向），再根据“x 源自 z”的置信度对该速度加权。对全部数据点做加权平均，就得到边缘向量场。

下面的交互图把这段话变成可以拨动的数字。为了让式 (18) 里的积分能手算，这里取只有三个数据点的一维玩具分布，并取 $\alpha_t = t$, $\beta_t = 1 - t$：此时式 (20) 化为 $\boldsymbol{u}_t(x|z) = (z - x)/(1 - t)$，每个条件向量场都指向各自的 z。拖动 t 与观察点 x：上方是边缘密度与按先验加权的各条件密度，下方每个箭头是一个条件向量场 $\boldsymbol{u}_t(x|z_k)$，粗箭头是它们按后验权重加权平均得到的边缘向量场 $\boldsymbol{u}_t(x)$。t 的上限取 0.95，因为式 (20) 在 $\beta_t = 0$（即 $t = 1$）处无定义。



数据点	位置 z_k	后验权重 w_k	条件速度 $u_t(x\|z_k)$
z_1	-2.0	0.18	-4.00
z_2	1.0	0.80	2.00
z_3	2.6	0.02	5.20
边缘速度 $u_t(x) = \Sigma\, w_k \cdot u_t(x\|z_k)$			**1.00**

时间 t = **0.50** （β_t = 0.50）

观察点 x = **0.00**

图例：上图实线为边缘密度 $p_t(x)$，虚线为按先验加权的各条件密度，竖线为观察点 x。下图每行箭头是条件速度（颜色越深，后验权重越大），最下面的粗箭头是边缘速度；箭头按固定比例绘制，过长时截短。

✦ 交互图 B · 边缘化技巧：一维玩具数据分布，三个数据点 $z_1 = -2.0$、$z_2 = 1.0$、$z_3 = 2.6$，先验 0.4 / 0.4 / 0.2，$\alpha_t = t$，$\beta_t = 1 - t$。

2.4. 连续性方程

本节剩余部分会把上述直观理解严格化，并证明定理 9。我们使用的核心数学工具是**连续性方程**，它是数学与物理中的基础方程。定义散度算子 div：

$$\operatorname{div}(\boldsymbol{v}_t)(x) = \sum_{i=1}^{d} \frac{\partial}{\partial x_i} v_{t,i}(x) \tag{22}$$

式中 $v_{t,i}$ 是向量 $\boldsymbol{v}_t$ 的第 i 个分量。

定理 11 · 连续性方程

考虑一个流模型，其向量场为 $\boldsymbol{u}_t^{\text{target}}$，且初始分布满足 $X_0 \sim p_{\text{init}} = p_0$。则对任意 $0 \le t \le 1$，$X_t \sim p_t$ 的充要条件是：

$$\partial_t p_t(x) = -\operatorname{div}\big(p_t \boldsymbol{u}_t^{\text{target}}\big)(x), \quad \forall x \in \mathbb{R}^d,\ 0 \le t \le 1 \tag{23}$$

其中 $\partial_t p_t(x) = \frac{d}{dt} p_t(x)$ 代表 $p_t(x)$ 关于时间的导数。式 (23) 即为**连续性方程**。

面向数学方向的读者，我们在附录 B 给出连续性方程自洽完整的证明。

继续推导之前，我们先从直观上理解连续性方程。方程左侧 $\partial_t p_t(x)$ 刻画位置 x 处的概率 $p_t(x)$ 随时间的变化量。直观来看，该变化量等价于**概率质量的净流入量**。在流模型中，粒子 X_t 沿着向量场 $\boldsymbol{u}_t^{\text{target}}$ 运动。回忆物理中的概念：散度描述向量场的净流出效应。因此，负散度代表净流入；将其乘以当前位置 x 处的总概率质量，就得到 $-\operatorname{div}(p_t \boldsymbol{u}_t)$，也就是概率质量的净流入总量。由于概率质量守恒（积分恒等于 1），方程左右两端必然相等！

接下来我们证明定理 9 中的边缘化技巧。

2.5. 定理 9 的证明

由定理 11 可知，我们只需证明：按式 (18) 定义的边缘化向量场 $\boldsymbol{u}_t^{\text{target}}$ 满足连续性方程。我们可以通过直接推导完成证明：

$$
\begin{aligned}
\partial_t p_t(x) &\overset{(i)}{=} \partial_t \int p_t(x|z)\, p_{\text{data}}(z)\, dz = \int \partial_t p_t(x|z)\, p_{\text{data}}(z)\, dz \\
&\overset{(ii)}{=} \int -\text{div}\big(p_t(\cdot|z)\boldsymbol{u}_t^{\text{target}}(\cdot|z)\big)(x)\, p_{\text{data}}(z)\, dz \\
&\overset{(iii)}{=} -\text{div}\left(\int p_t(x|z)\boldsymbol{u}_t^{\text{target}}(x|z)\, p_{\text{data}}(z)\, dz\right) \\
&\overset{(iv)}{=} -\text{div}\left(p_t(x)\int \boldsymbol{u}_t^{\text{target}}(x|z)\, \frac{p_t(x|z)p_{\text{data}}(z)}{p_t(x)} dz\right)(x) \\
&\overset{(v)}{=} -\text{div}\big(p_t \boldsymbol{u}_t^{\text{target}}\big)(x),
\end{aligned}
$$

其中：(i) 使用式 (12) 中 $p_t(x)$ 的定义；(ii) 对条件概率路径 $p_t(\cdot|z)$ 应用连续性方程；(iii) 利用式 (22) 交换积分与散度算子；(iv) 分子分母同乘、同除 $p_t(x)$；(v) 代入式 (18)。

上述等式链的首尾说明：向量场 $\boldsymbol{u}_t^{\text{target}}$ 满足连续性方程。结合定理 11，即可推得式 (19)，证毕。

03. 流匹配：学习边缘化向量场

接下来我们介绍训练算法。流匹配（Flow Matching）的目标是训练神经网络 $\boldsymbol{u}_t^\theta$，使其逼近边缘化向量场 $\boldsymbol{u}_t^{\text{target}}$。若该逼近成立，则根据定理 9，终点 $X_1 \sim p_{\text{data}}$ 将服从我们期望的数据分布。

下文记 $\text{Unif} = \text{Unif}[0,1]$ 为区间 $[0,1]$ 上的均匀分布，$\mathbb{E}$ 表示随机变量的期望。

3.1. 流匹配损失

想要得到 $\boldsymbol{u}_t^\theta \approx \boldsymbol{u}_t^{\text{target}}$，一个直观方案是采用均方误差，也就是定义**流匹配损失**：

$$
\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},\, x\sim p_t}\left[\|\boldsymbol{u}_t^\theta(x) - \boldsymbol{u}_t^{\text{target}}(x)\|^2\right] \tag{24}
$$

$$
\mathcal{L}_{\text{FM}}(\theta) \overset{(i)}{=} \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)}\left[\|\boldsymbol{u}_t^\theta(x) - \boldsymbol{u}_t^{\text{target}}(x)\|^2\right] \tag{25}
$$

其中 $p_t(x) = \int p_t(x|z)\, p_{\text{data}}(z)\, dz$ 是边缘概率路径；等式 (i) 利用了式 (12) 给出的采样方式。

直观理解这个损失：首先从 $[0,1]$ 随机采样时间 t；然后从数据集采样隐变量 z，再从条件路径 $p_t(\cdot|z)$ 采样样本 x（例如通过加噪声），并计算网络输出 $\boldsymbol{u}_t^\theta(x)$；最后计算神经网络输出与边缘化向量场 $\boldsymbol{u}_t^{\text{target}}(x)$ 之间的均方误差。

但问题并未就此解决。虽然定理 9 给出了 $\boldsymbol{u}_t^{\text{target}}$ 的表达式，但该式包含难以求解的积分，无法高效计算。为此我们利用**条件速度场 $\boldsymbol{u}_t^{\text{target}}(x|z)$ 是可解析求解**这一性质。

3.2. 条件流匹配损失

我们定义**条件流匹配损失**：

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)}\left[\|\boldsymbol{u}_t^\theta(x) - \boldsymbol{u}_t^{\text{target}}(x|z)\|^2\right]. \tag{26}$$

对比式 (24) 可以看到区别：这里用**条件向量场 $\boldsymbol{u}_t^{\text{target}}(x|z)$**，而非边缘化向量场 $\boldsymbol{u}_t^{\text{target}}(x)$。由于 $\boldsymbol{u}_t^{\text{target}}(x|z)$ 存在解析表达式，我们可以很方便地最小化上述损失。

但这里会产生疑问：我们真正关心的是边缘化向量场，那为什么要对条件向量场做回归？结论是：**通过直接对可计算的条件向量场做回归，等价于隐式地对难以求解的边缘化向量场做回归**。下面的定理将严格表述这一直观结论。

定理 12 · 两种损失只差一个常数

边缘化流匹配损失与条件流匹配损失仅相差一个常数。即：

$$\mathcal{L}_{\text{FM}}(\theta) = \mathcal{L}_{\text{CFM}}(\theta) + C$$

其中常数 C 与参数 θ 无关。因此二者梯度相等：

$$\nabla_\theta \mathcal{L}_{\text{FM}}(\theta) = \nabla_\theta \mathcal{L}_{\text{CFM}}(\theta).$$

由此，采用随机梯度下降（SGD）等算法最小化 $\mathcal{L}_{\text{CFM}}(\theta)$，等价于以相同方式最小化 $\mathcal{L}_{\text{FM}}(\theta)$。特别地，$\mathcal{L}_{\text{CFM}}(\theta)$ 的极小值点 θ^* 满足 $\boldsymbol{u}_t^{\theta^*} = \boldsymbol{u}_t^{\text{target}}$；也就是说，在网络表达能力无限的假设下，神经网络将精确等于边缘化向量场。

Algorithm 3 流匹配训练流程（一般情形，Flow Matching Training Procedure · General）

输入：由数据样本 $z \sim p_{\text{data}}$ 构成的数据集，神经网络 u_t^θ

1: **for** 每个 mini-batch 的数据 **do**
2: 从数据集中采样一个数据样本 z
3: 采样随机时间 $t \sim \text{Unif}_{[0,1]}$
4: 采样 $x \sim p_t(\cdot|z)$
5: 计算损失

$$\mathcal{L}(\theta) = \left\| u_t^\theta(x) - u_t^{\text{target}}(x|z) \right\|^2$$

6: 对 $\mathcal{L}(\theta)$ 做梯度下降，更新模型参数 θ
7: **end for**

✦ Algorithm 3 · 流匹配训练流程（一般情形，据原讲义重排）。

3.3. 定理 12 的直接证明

证明思路：将均方误差展开为三项，分离出不含参数的常数项。

$$\begin{aligned}
\mathcal{L}_{\text{FM}}(\theta) &\overset{(i)}{=} \mathbb{E}_{t\sim\text{Unif},\, x\sim p_t}\left[\left\|\boldsymbol{u}_t^\theta(x) - \boldsymbol{u}_t^{\text{target}}(x)\right\|^2\right] \\
&\overset{(ii)}{=} \mathbb{E}_{t\sim\text{Unif},\, x\sim p_t}\Big[\|\boldsymbol{u}_t^\theta(x)\|^2 - 2\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\text{target}}(x) \\
&\qquad\qquad + \|\boldsymbol{u}_t^{\text{target}}(x)\|^2\Big] \\
&\overset{(iii)}{=} \mathbb{E}_{t\sim\text{Unif},\, x\sim p_t}\left[\|\boldsymbol{u}_t^\theta(x)\|^2\right] - 2\mathbb{E}_{t\sim\text{Unif},\, x\sim p_t}\left[\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\text{target}}(x)\right] \\
&\qquad + \underbrace{\mathbb{E}_{t\sim\text{Unif}[0,1],\, x\sim p_t}\left[\|\boldsymbol{u}_t^{\text{target}}(x)\|^2\right]}_{:=C_1} \\
&\overset{(iv)}{=} \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)}\left[\|\boldsymbol{u}_t^\theta(x)\|^2\right] \\
&\qquad - 2\mathbb{E}_{t\sim\text{Unif},\, x\sim p_t}\left[\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\text{target}}(x)\right] + C_1
\end{aligned}$$

其中：(i) 由定义成立；(ii) 使用向量范数展开公式 $\|a-b\|^2 = \|a\|^2 - 2a^\top b + \|b\|^2$；(iii) 定义常数 C_1；(iv) 使用式 (12) 给出的 p_t 的采样方式。

我们对第二项重新变形：

$$
\begin{aligned}
\mathbb{E}_{t\sim\mathrm{Unif},\,x\sim p_t}\left[\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\mathrm{target}}(x)\right] &\overset{(i)}{=} \int_0^1 \int p_t(x)\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\mathrm{target}}(x)\,dx\,dt \\
&\overset{(ii)}{=} \int_0^1 \int p_t(x)\boldsymbol{u}_t^\theta(x)^\top \\
&\qquad \cdot \left(\int \boldsymbol{u}_t^{\mathrm{target}}(x|z)\frac{p_t(x|z)p_{\mathrm{data}}(z)}{p_t(x)}dz\right) dx\,dt \\
&\overset{(iii)}{=} \int_0^1 \iint \boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\mathrm{target}}(x|z)\, p_t(x|z)p_{\mathrm{data}}(z)\,dz\,dx\,dt \\
&\overset{(iv)}{=} \mathbb{E}_{t\sim\mathrm{Unif},\,z\sim p_{\mathrm{data}},\,x\sim p_t(\cdot|z)}\left[\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\mathrm{target}}(x|z)\right]
\end{aligned}
$$

← 左右滑动查看 →

其中：(i) 将期望写成积分形式；(ii) 代入式 (18)；(iii) 利用积分的线性性质；(iv) 将积分改写为期望形式。

这一步是整个证明最关键的一步：等式左端采用边缘化向量场 $\boldsymbol{u}_t^{\mathrm{target}}(x)$，而等式右端替换为条件向量场 $\boldsymbol{u}_t^{\mathrm{target}}(x|z)$。

将该结果代入 $\mathcal{L}_{\mathrm{FM}}(\theta)$ 的表达式可得：

$$
\begin{aligned}
\mathcal{L}_{\mathrm{FM}}(\theta) &\overset{(i)}{=} \mathbb{E}_{t\sim\mathrm{Unif},\,z\sim p_{\mathrm{data}},\,x\sim p_t(\cdot|z)}\left[\|\boldsymbol{u}_t^\theta(x)\|^2\right] \\
&\qquad - 2\mathbb{E}_{t\sim\mathrm{Unif},\,z\sim p_{\mathrm{data}},\,x\sim p_t(\cdot|z)}\left[\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\mathrm{target}}(x|z)\right] + C_1 \\
&\overset{(ii)}{=} \mathbb{E}_{t\sim\mathrm{Unif},\,z\sim p_{\mathrm{data}},\,x\sim p_t(\cdot|z)}\Big[\|\boldsymbol{u}_t^\theta(x)\|^2 - 2\boldsymbol{u}_t^\theta(x)^\top \boldsymbol{u}_t^{\mathrm{target}}(x|z) \\
&\qquad\qquad + \|\boldsymbol{u}_t^{\mathrm{target}}(x|z)\|^2 - \|\boldsymbol{u}_t^{\mathrm{target}}(x|z)\|^2\Big] + C_1 \\
&\overset{(iii)}{=} \mathbb{E}_{t\sim\mathrm{Unif},\,z\sim p_{\mathrm{data}},\,x\sim p_t(\cdot|z)}\left[\|\boldsymbol{u}_t^\theta(x) - \boldsymbol{u}_t^{\mathrm{target}}(x|z)\|^2\right] \\
&\qquad + \underbrace{\mathbb{E}_{t\sim\mathrm{Unif},\,z\sim p_{\mathrm{data}},\,x\sim p_t(\cdot|z)}\left[-\|\boldsymbol{u}_t^{\mathrm{target}}(x|z)\|^2\right]}_{C_2} + C_1 \\
&\overset{(iv)}{=} \mathcal{L}_{\mathrm{CFM}}(\theta) + \underbrace{C_2 + C_1}_{:=C}
\end{aligned}
$$

其中：(i) 代入上一步推导得到的等式；(ii) 对表达式同加同减一项；(iii) 再次使用范数展开公式 $\|a-b\|^2 = \|a\|^2 - 2a^\top b + \|b\|^2$；(iv) 合并得到与参数 θ 无关的常数。至此证明完毕。

3.4. 训练流程

因此，流匹配训练的核心就是最小化条件流匹配损失。训练流程汇总如算法 3 所示，可视化见图 7。该算法具有几个非常突出的特点：

第一，**训练过程中完全不需要求解常微分方程（ODE）**，该特性被称为**无仿真（simulation-free）**。这极大降低了训练开销，训练阶段无需迭代推演 ODE 的轨迹（轨迹推演需要大量迭代步）。

第二，训练目标本质上是简单的回归任务：仅对 $\boldsymbol{u}_t^{\text{target}}(x|z)$ 做回归。从这个角度看，它和监督学习并无太大区别。

第三，该算法形式极其简洁，很难设计出比它更简单的训练目标。

以上优点使得流匹配非常适合大规模机器学习模型。训练得到 $\boldsymbol{u}_t^\theta$ 之后，我们可以通过例如算法 1，仿真流模型

$$dX_t = \boldsymbol{u}_t^\theta(X_t)\,dt, \quad X_0 \sim p_{\text{init}} \tag{27}$$

得到样本 $X_1 \sim p_{\text{data}}$。整套流程在文献中被称为流匹配（Flow Matching）。下面我们针对高斯概率路径实例化条件流匹配损失。

Algorithm 3 流匹配训练流程（高斯 CondOT 路径 $p_t(x|z) = \mathcal{N}(tz, (1-t)^2)$）

输入：由数据样本 $z \sim p_{\text{data}}$ 构成的数据集，神经网络 u_t^θ

1: **for** 每个 mini-batch 的数据 **do**
2: 从数据集中采样一个数据样本 z
3: 采样随机时间 $t \sim \text{Unif}_{[0,1]}$
4: 采样噪声 $\epsilon \sim \mathcal{N}(0, I_d)$
5: 设 $x = tz + (1-t)\epsilon$ ◂ 一般情形：$x \sim p_t(\cdot \mid z)$
6: 计算损失 $\mathcal{L}(\theta) = \left\| u_t^\theta(x) - (z - \epsilon) \right\|^2$ ◂ 一般情形：$= \left\| u_t^\theta(x) - u_t^{\text{target}}(x|z) \right\|^2$
7: 更新 $\theta \leftarrow \text{grad_update}(\mathcal{L}(\theta))$
8: **end for**

✦ Algorithm 3 · 流匹配训练流程（高斯 CondOT 路径，据原讲义重排；右侧批注为原讲义对应一般情形的写法）。

3.5. 例 13：高斯条件概率路径下的流匹配

例 13

回到高斯概率路径的例子：$p_t(\cdot|z) = \mathcal{N}\left(\alpha_t z; \beta_t^2 I_d\right)$。可以按如下方式从条件路径采样：

$$\begin{gathered} \varepsilon \sim \mathcal{N}(0, I_d) \Rightarrow \\ x_t = \alpha_t z + \beta_t \varepsilon \sim \mathcal{N}(\alpha_t z, \beta_t^2 I_d) = p_t(\cdot|z). \end{gathered} \tag{28}$$

由式 (20) 的推导结果，条件向量场 $\boldsymbol{u}_t^{\text{target}}(x|z)$ 表达式为：

$$\boldsymbol{u}_t^{\text{target}}(x|z) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z + \frac{\dot{\beta}_t}{\beta_t} x, \tag{29}$$

其中 $\dot{\alpha}_t = \partial_t \alpha_t$，$\dot{\beta}_t = \partial_t \beta_t$ 分别为对应关于时间的导数。

将该式代入，条件流匹配损失写作：

$$\begin{gathered} \mathcal{L}_{\text{CFM}}(\theta) = \\ \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim\mathcal{N}(\alpha_t z, \beta_t^2 I_d)} \left[\left\| \boldsymbol{u}_t^\theta(x) - \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z - \frac{\dot{\beta}_t}{\beta_t} x \right\|^2\right] \end{gathered} \tag{30}$$

$$\begin{gathered} \mathcal{L}_{\text{CFM}}(\theta) \overset{(i)}{=} \\ \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, \varepsilon\sim\mathcal{N}(0, I_d)} \left[\left\| \boldsymbol{u}_t^\theta(\alpha_t z + \beta_t \varepsilon) - \left(\dot{\alpha}_t z + \dot{\beta}_t \varepsilon\right) \right\|^2\right] \end{gathered} \tag{31}$$

式 (i) 代入式 (28)，将 x 替换为 $\alpha_t z + \beta_t \varepsilon$。可以看到 $\mathcal{L}_{\text{CFM}}$ 形式十分简洁：采样一个数据点 z，采样噪声 ε，然后计算均方误差。

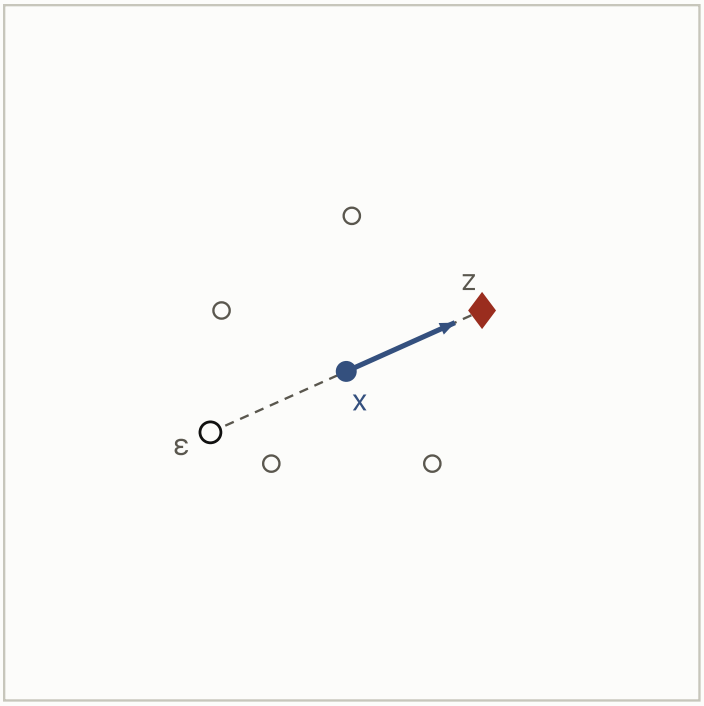
我们进一步取特例：令 $\alpha_t = t$，$\beta_t = 1 - t$。对应的概率分布 $p_t(x|z) = \mathcal{N}\left(tz, (1-t)^2 I_d\right)$ 有时被称为**高斯 CondOT 概率路径**。此时 $\dot{\alpha}_t = 1, \dot{\beta}_t = -1$，于是

$$\begin{gathered} \mathcal{L}_{\text{CFM}}(\theta) = \\ \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, \varepsilon\sim\mathcal{N}(0, I_d)} \left[\left\| \boldsymbol{u}_t^\theta\big(tz + (1-t)\varepsilon\big) - (z - \varepsilon) \right\|^2\right] \end{gathered}$$

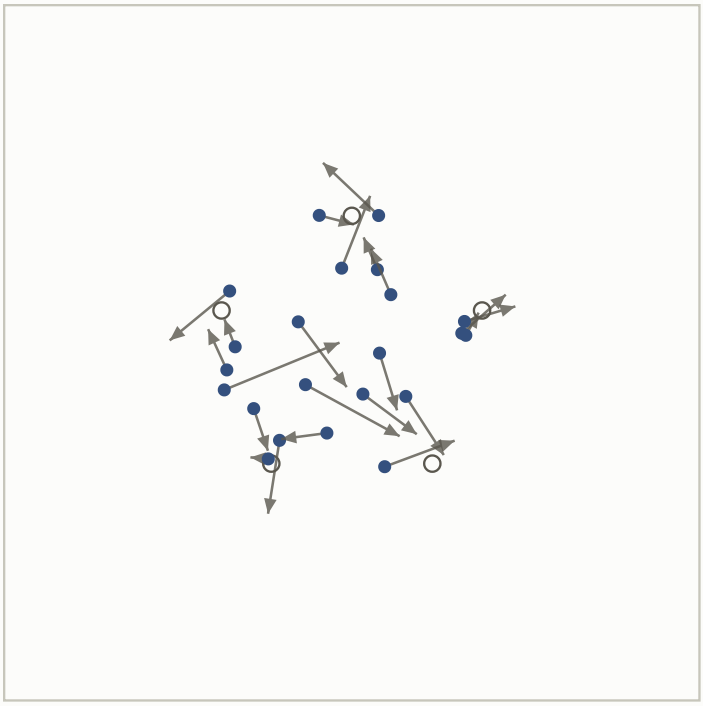
式 (31) 的 CondOT 特例可以直接动手看：左图固定一个数据点 z 与一个噪声 ε，拖动 t，输入位置 $x = tz + (1-t)\varepsilon$ 沿着 $\varepsilon \to z$ 的直线移动，而回归目标 $z - \varepsilon$ 始终不变；右图是一个 mini-batch，每个训练样本各有自己的 (z, ε, t)，每个点是网络的输入位置，箭头是它要回归的目标。窄屏下两图上

下排列，左图即上方。

一个训练样本：z = z_2，噪声 ε 固定



一个 mini-batch：每个样本各有自己的 z、ε、t



时间 t = **0.50**　α_t = 0.50，β_t = 0.50

数据点（取各簇中心）：z_1 z_2 z_3 z_4 z_5　重抽 ε 与 mini-batch

x = t·z + (1−t)·ε = (-0.06, 0.21)；回归目标 z − ε = (3.07, -1.38)，与 t 无关：拖动 t 时只有 x 在直线上移动，箭头的方向与长度都不变。

图例：空心圆为数据簇中心，红色菱形为 z，空心点为 ε，深色实心点为输入位置 x，箭头为回归目标（按 0.4 倍缩放绘制）；右图中落在画面外的样本不绘制。

✦ 交互图 C · 高斯 CondOT 路径的回归目标（$\alpha_t = t$，$\beta_t = 1 - t$）。

许多知名的前沿模型都采用这套简单且高效的流程进行训练，例如 Stable Diffusion 3、Meta 的 Movie Gen 视频模型，以及大量闭源模型。图 7 在简单示例上对该流程做可视化，算法 3 总结了完整训练步骤。

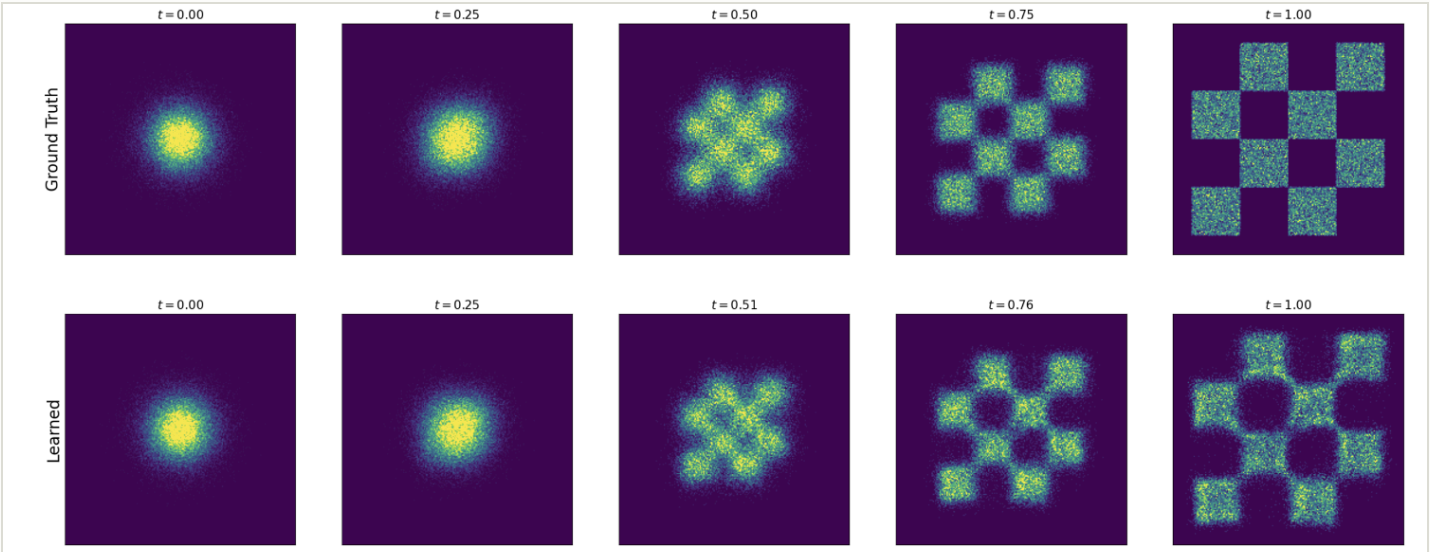


Figure 7: Illustration of Theorem 12 with a Gaussian CondOT probability path: simulating an ODE from a trained flow matching model. The data distribution is the chess board pattern (top right). Top row: Histogram from ground truth marginal probability path $p_t(x)$. Bottom row: Histogram of samples from flow matching model. As one can see, the top row and bottom row match after training (up to training error). The model was trained using Algorithm 3.

图 7. 定理 12 图示：高斯 CondOT 概率路径下，用训练好的流匹配模型仿真 ODE。数据分布为棋盘格（右上）。上排：真值边缘概率路径 $p_t(x)$ 的直方图；下排：流匹配模型样本的直方图。可以看到，训练之后上下两排吻合（相差训练误差）。该模型使用算法 3 训练。 · 来源：MIT 6.S184 讲义

3.6. 小结 14：流匹配

小结 14（流匹配 Flow Matching） 流匹配训练的目标是学习边缘化向量场 $\boldsymbol{u}_t^{\text{target}}$。为构造该向量场，首先选取一条条件概率路径 $p_t(x|z)$，满足边界条件 $p_0(\cdot|z) = p_{\text{init}}$，$p_1(\cdot|z) = \delta_z$。接下来求解条件向量场 $\boldsymbol{u}_t^{\text{target}}(x|z)$，使其对应的流映射 $\psi_t^{\text{target}}(x|z)$ 满足：

$$X_0 \sim p_{\text{init}} \Rightarrow X_t = \psi_t^{\text{target}}(X_0|z) \sim p_t(\cdot|z),$$

等价地，要求 $\boldsymbol{u}_t^{\text{target}}$ 满足连续性方程。

由此定义的边缘化向量场：

$$\boldsymbol{u}_t^{\text{target}}(x) = \int \boldsymbol{u}_t^{\text{target}}(x|z) \frac{p_t(x|z)\, p_{\text{data}}(z)}{p_t(x)} dz \tag{32}$$

将沿着边缘概率路径演化，即：

$$X_0 \sim p_{\text{init}}, \quad dX_t = \boldsymbol{u}_t^{\text{target}}(X_t)dt \\ \Rightarrow X_t \sim p_t, \quad (0 \le t \le 1). \tag{33}$$

特别地，该常微分方程演化得到 $X_1 \sim p_{\text{data}}$，即 $\boldsymbol{u}_t^{\text{target}}$ 能够按预期“将噪声转化为数据”。

为学习该向量场，我们最小化条件流匹配损失：

$$\mathcal{L}_{\text{CFM}}(\theta) = \\ \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)}\left[\|\boldsymbol{u}_t^\theta(x) - \boldsymbol{u}_t^{\text{target}}(x|z)\|^2\right]. \tag{34}$$

应用最广泛的实例为高斯概率路径，此时公式为：

$$p_t(x|z) = \mathcal{N}\left(x; \alpha_t z, \beta_t^2 I_d\right) \tag{35}$$

$$\boldsymbol{u}_t^{\text{flow}}(x|z) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z + \frac{\dot{\beta}_t}{\beta_t} x \tag{36}$$

$$\mathcal{L}_{\text{CFM}}(\theta) = \\ \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, \varepsilon\sim\mathcal{N}(0,I_d)}\left[\|\boldsymbol{u}_t^\theta(\alpha_t z + \beta_t \varepsilon) - \left(\dot{\alpha}_t z + \dot{\beta}_t \varepsilon\right)\|^2\right] \tag{37}$$

其中 $\alpha_t, \beta_t \in \mathbb{R}$ 为噪声调度函数，是连续可微的单调函数，选取时满足 $\alpha_0 = \beta_1 = 0$, $\alpha_1 = \beta_0 = 1$（例如取 $\alpha_t = t, \beta_t = 1 - t$）。

结语：流匹配损失与条件流匹配损失对照

下表把正文中散落的事实并排放在一起：

表 1. 流匹配损失与条件流匹配损失对照

维度	流匹配损失（式 (24)）	条件流匹配损失（式 (26)）
回归目标	边缘化向量场 $\boldsymbol{u}_t^{\text{target}}(x)$	条件向量场 $\boldsymbol{u}_t^{\text{target}}(x\|z)$
采样方式	$t \sim \text{Unif}$, $x \sim p_t$，等价于先采 z 再采 x（式 (25)）	$t \sim \text{Unif}$, $z \sim p_{\text{data}}$, $x \sim p_t(\cdot\|z)$
能否高效计算	不能：式 (18) 含难以求解的积分	能：条件向量场有解析表达式
二者关系	$\mathcal{L}_{\text{FM}} = \mathcal{L}_{\text{CFM}} + C$，$C$ 与 θ 无关	$\nabla_\theta \mathcal{L}_{\text{CFM}} = \nabla_\theta \mathcal{L}_{\text{FM}}$（定理 12）
极小值点	见右栏（定理 12）	$\boldsymbol{u}_t^{\theta^*} = \boldsymbol{u}_t^{\text{target}}$（网络表达能力无限时，定理

← 左右滑动查看 →

对高斯概率路径，条件流匹配损失化为式 (31)；取 CondOT（$\alpha_t = t$, $\beta_t = 1 - t$）时只需回归 $z - \varepsilon$。训练过程不需要仿真 ODE（simulation-free，算法 3）。

从表中可以看出：回归可算的条件向量场，等价于回归难算的边缘化向量场。训练完成后，再用算法 1 仿真式 (27) 的 ODE，就得到服从数据分布的样本。