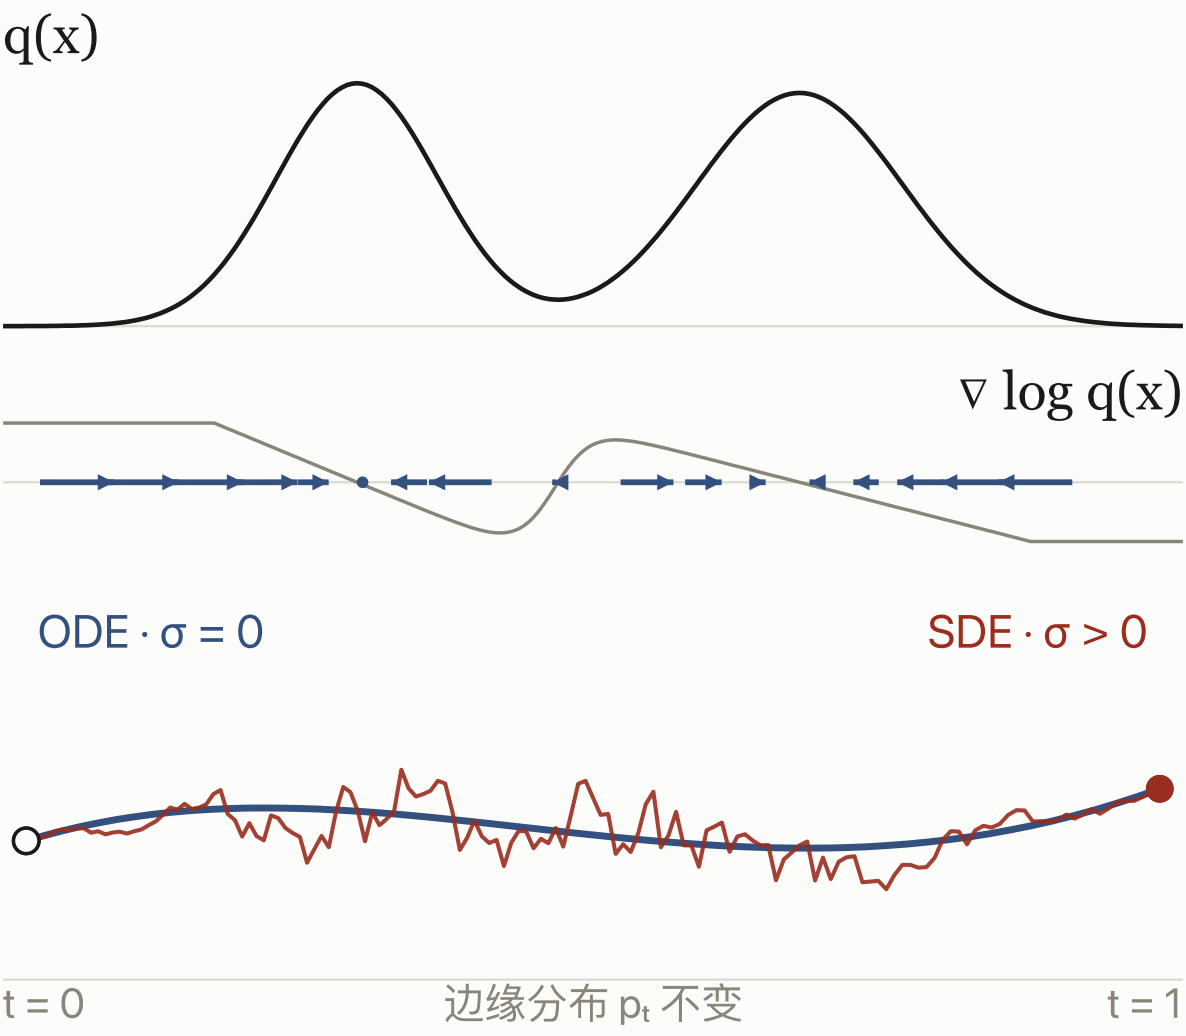
FLOW MATCHING & DIFFUSION · NOTES 03

向峰顶走一步，再抖一下

Score function 让带噪的 SDE 仍然走同一条概率路径



目录

01 Conditional Score 与 Marginal Score

1.1 Score Function

1.2 Conditional Score 与 Marginal Score

1.3 高斯概率路径的 Score Function

1.4 向量场与 Score 的转换

1.5 Score 的重参数化与去噪器

02 基于 SDE 的采样

2.1 SDE 扩展技巧

2.2 福克-普朗克方程

2.3 定理 17 的证明

2.4 朗之万动力学

2.5 GLASS 流

03 Score Matching

3.1 Score Matching 损失

3.2 定理 22：两种损失只差一个常数

3.3 例 23：去噪扩散模型

3.4 小结 24：Score Function、Score Matching 与随机采样

Score Function：给流加噪声，再补上 score 修正，路径不变

读完能写出 denoising score matching（DDPM）的训练算法与任意 σ_t 的 SDE 采样式，并说清 u、s、D 三者的换算

课程： MIT 6.S184 Flow Matching & Diffusion Models　类型： 个人学习笔记　日期： 2026-10

上一讲用向量场训练流模型。本讲换成扩散模型常用的 score function 语言：先说明两者在高斯路径下可以互相换算，再借福克-普朗克方程证明 SDE 采样的扩展技巧，最后给出 denoising score matching 与 DDPM 损失。

三句话读懂本讲

1. 高斯概率路径下，向量场与 score function 可以互相换算（命题 1）：学到一个就等价于学到另一个，去噪器（后验均值）是第三种等价的参数化。
2. 定理 17：在 ODE 上叠加 $\sigma_t^2/2 \cdot \nabla \log p_t$ 的修正项与布朗噪声，得到的 SDE 仍然沿着同一条概率路径；训练完成后，扩散系数 σ_t 可以任选。
3. 定理 22：conditional score matching 与 score matching 只差一个常数；高斯路径下它就是 denoising score matching，舍去 $1/\beta_t^2$ 并改为预测噪声，就得到 DDPM 的损失。

01. Conditional Score 与 Marginal Score

上一节我们介绍了如何利用流匹配（flow matching）训练流模型。本节将讨论扩散模型，并说明如何使用 score matching 对其进行训练。

1.1. Score Function

到目前为止，我们研究的核心对象是向量场 $\boldsymbol{u}_t(x)$。扩散模型 [45, 44] 采用了另一种视角，其研究重点是 score function。因此，本节我们将用 score function 的语言重新表述前面学到的内容，提供一套全新的理解视角。

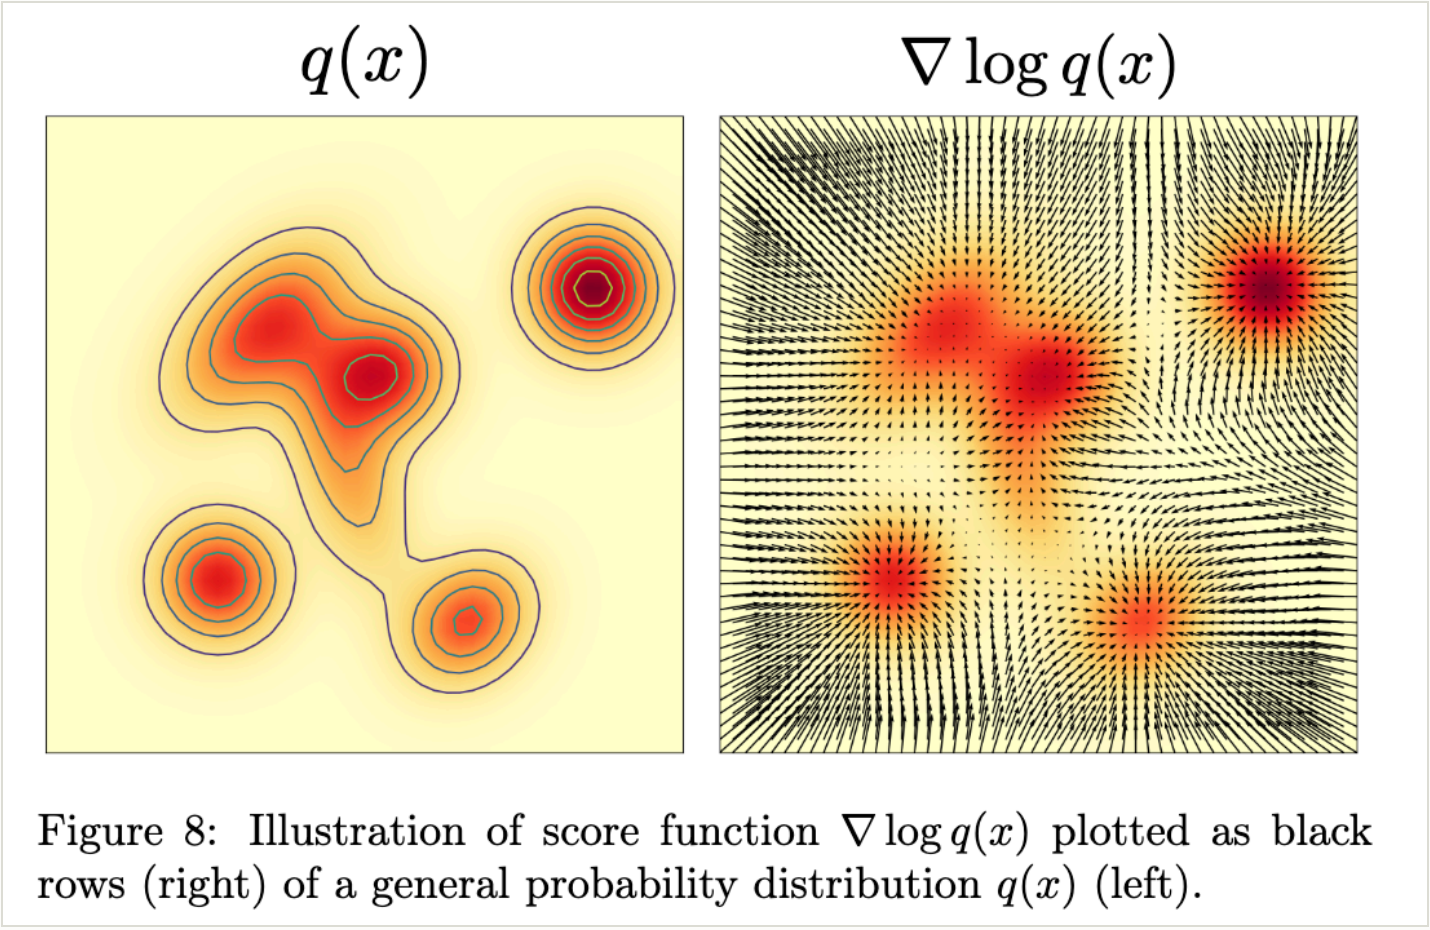
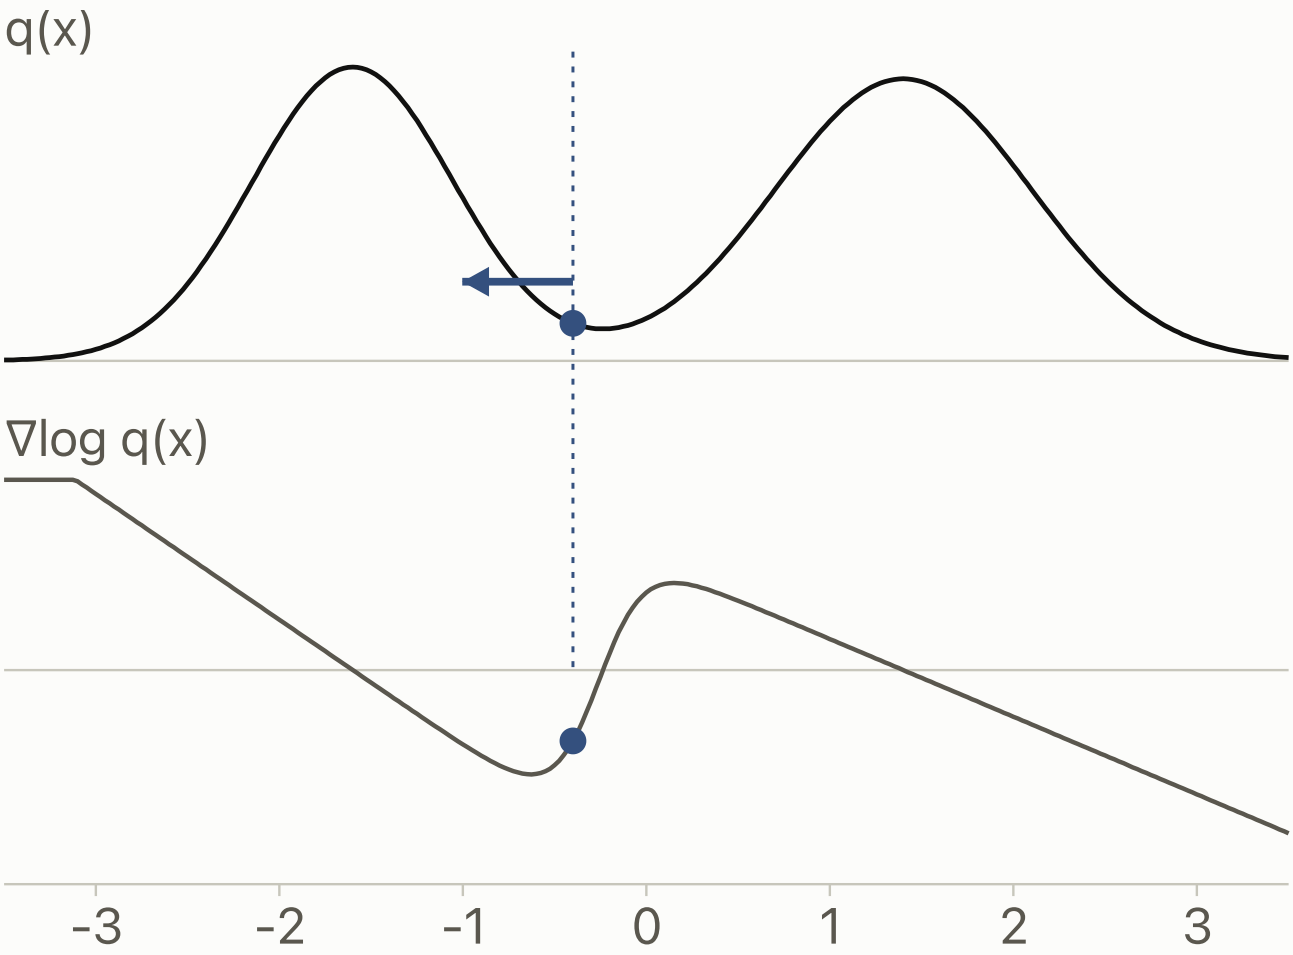


Figure 8: Illustration of score function $\nabla \log q(x)$ plotted as black rows (right) of a general probability distribution $q(x)$ (left).

图 8. 一般概率分布 q(x)（左）及其 score function ∇log q(x)（右，黑色箭头）的示意。 · 来源：MIT 6.S184 讲义

设 $q(x)$ 为任意概率分布，则 q 的 **score function** 定义为 $\nabla \log q(x)$，也就是对数似然关于 x 的梯度。score 的直观含义是：$\nabla \log q(x)$ 是对数似然的**最速上升方向**，如图 8 所示。

图 8 是二维的静态图。下面的交互图把维度降到一维，让你拖动位置自己看：score 在密度升高的一侧为正、降低的一侧为负，峰顶与谷底处为 0。



位置 x = **-0.40**

q(x) = 0.042 · ∇log q(x) = -1.86

score 为负：对数似然上升最快的方向是向左（箭头向左）。

图例：上图实线为密度 q(x)，下图曲线为 score ∇log q(x)（纵向只画 |score| ≤ 5，读数为真实值）；圆点为当前位置，箭头沿 score 方向（长度按固定比例绘制，过长时截短）。

✦ 交互图 A · Score Function（一维双峰混合 q(x) = 0.45·N(−1.6, 0.55²) + 0.55·N(1.4, 0.7²)）。拖动位置 x：上图为密度，下图为 score ∇log q(x)，箭头沿 score 方向。

1.2. Conditional Score 与 Marginal Score

回到第 3 节（即上一讲）中条件概率路径 $p_t(x|z)$ 和边缘概率路径 $p_t(x)$ 的设定。我们可以相应定义 **conditional score function** 为 $\nabla \log p_t(x|z)$，**marginal score function** 为 $\nabla \log p_t(x)$。与式 (18) 类似，marginal score 可以借助conditional score function $\nabla \log p_t(x|z)$ 写为：

$$\nabla \log p_t(x) = \int \nabla \log p_t(x|z) \, \frac{p_t(x|z)\, p_{\text{data}}(z)}{p_t(x)} \, dz \tag{38}$$

由此可见，conditional score 与 marginal score 之间的关系，和条件向量场与边缘向量场之间的关系是相似的。式 (38) 可按如下方式证明：

$$\begin{aligned}\nabla \log p_t(x) &= \frac{\nabla p_t(x)}{p_t(x)} = \frac{\nabla \int p_t(x|z)\, p_{\text{data}}(z)\, dz}{p_t(x)} \\ &= \frac{\int \nabla p_t(x|z)\, p_{\text{data}}(z)\, dz}{p_t(x)} = \int \nabla \log p_t(x|z)\, \frac{p_t(x|z)\, p_{\text{data}}(z)}{p_t(x)}\, dz\end{aligned} \tag{39}$$

← 左右滑动查看 →

推导过程使用求导公式 $\partial_y \log y = 1/y$，并两次应用链式法则。

1.3. 高斯概率路径的 Score Function

例 15 · 高斯概率路径的 Score Function

对于高斯路径 $p_t(x|z) = \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d)$，利用高斯概率密度公式（见式 (97)）可得：

$$\nabla \log p_t(x|z) = \nabla \log \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d) = -\frac{x - \alpha_t z}{\beta_t^2} \tag{40}$$

推导如下（原讲义以图片给出，此处重排）：

$$\begin{aligned}p_t(x|z) = \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d) &= \frac{1}{(2\pi)^{d/2}\beta_t^d} \exp\left(-\frac{1}{2\beta_t^2}\|x - \alpha_t z\|^2\right) \\ \log p_t(x|z) = \log \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d) &= -\frac{d}{2}\log(2\pi) - d\log\beta_t - \frac{1}{2\beta_t^2}\|x - \alpha_t z\|^2 \\ \nabla \log p_t(x|z) = \nabla \log \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d) &= -\frac{x - \alpha_t z}{\beta_t^2}\end{aligned}$$

注意，高斯概率路径的 score function 是关于 x 和 z 的线性函数。条件向量场 $\boldsymbol{u}_t(x|z)$ 同样具备该性质（见式 (20)）。因此二者可以相互转换，如下述命题所示。

1.4. 向量场与 Score 的转换

命题 1 · 高斯概率路径的转换公式

对于高斯概率路径 $p_t(x|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$，条件（相应地，边缘）向量场与条件（相应地，边缘）score 满足如下恒等式：

$$\boldsymbol{u}_t^{\text{target}}(x|z) = a_t \nabla \log p_t(x|z) + b_t x, \quad a_t = \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t \right), \quad b_t = \frac{\dot{\alpha}_t}{\alpha_t} \tag{41}$$

$$\boldsymbol{u}_t^{\text{target}}(x) = a_t \nabla \log p_t(x) + b_t x. \tag{42}$$

特别地，条件（相应地，边缘）向量场可以由条件（相应地，边缘）score 还原得到，反之亦然。

校注 · 系数 $\mathbf{a_t}$ 的写法

原笔记把 a_t 写作 $\beta_t^2 \dot{\alpha}_t/\alpha_t - \dot{\beta}_t/\beta_t$（式 (41)、下面证明的步骤 (i)、小结 24 三处），但按步骤 (i) 的代数展开，第二项应是 $\dot{\beta}_t \beta_t$，而不是 $\dot{\beta}_t/\beta_t$。验证如下（把 a_t 取校正后的写法代入步骤 (i) 的右侧）：

$$\left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t \right) \frac{\alpha_t z - x}{\beta_t^2} + \frac{\dot{\alpha}_t}{\alpha_t} x = \dot{\alpha}_t z - \frac{\dot{\beta}_t}{\beta_t} \alpha_t z + \frac{\dot{\beta}_t}{\beta_t} x = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) z + \frac{\dot{\beta}_t}{\beta_t} x$$

右端恰是式 (20) 的条件向量场。本文所有公式与交互图 B 都采用校正后的写法；去噪器式 (43)、小结 24 中式 (55)(56) 的互换与 a_t 的具体形式无关，不受影响。

证明：对于条件向量场与 conditional score，推导如下：

$$\begin{aligned} \boldsymbol{u}_t^{\text{target}}(x|z) &= \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) z + \frac{\dot{\beta}_t}{\beta_t} x \\ &\overset{(i)}{=} \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t \right) \left(\frac{\alpha_t z - x}{\beta_t^2} \right) + \frac{\dot{\alpha}_t}{\alpha_t} x \\ &= \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t \right) \nabla \log p_t(x|z) + \frac{\dot{\alpha}_t}{\alpha_t} x \end{aligned}$$

其中步骤 (i) 仅为代数变形。对式子积分，同样的恒等式对边缘流向量场和marginal score function 依然成立：

$$
\begin{aligned}
\boldsymbol{u}_t^{\text{target}}(x) &= \int \boldsymbol{u}_t^{\text{target}}(x|z)\,\frac{p_t(x|z)\,p_{\text{data}}(z)}{p_t(x)}\,dz \\
&= \int \left[a_t \nabla \log p_t(x|z) + b_t x\right] \frac{p_t(x|z)\,p_{\text{data}}(z)}{p_t(x)}\,dz \\
&\overset{(i)}{=} a_t \nabla \log p_t(x) + b_t x
\end{aligned}
$$

步骤 (i) 用到式 (38)，以及后验密度积分等于 1 这一性质。

命题 1 的结论十分重要：它说明一旦学习得到 $\boldsymbol{u}_t^{\text{target}}$，就等价学习到 score function $\nabla \log p_t(x)$，反之亦然。因此很多扩散模型通过神经网络直接学习 score function $\nabla \log p_t(x)$。我们将在后文第 03 节（原讲义 4.3 节）展开讨论。

1.5. Score 的重参数化与去噪器

注记 16 · Score 的重参数化

式 (41) 中高斯概率路径的重参数化公式之所以成立，是因为等式两端（条件向量场与 conditional score）都是关于 x 和 z 的线性函数。当我们做边缘化处理（得到边缘向量场与 marginal score）后，等式两端本质上都是后验均值 $\mathbb{E}_{z|x}[z]$ 的线性重参数化。由此可知：任何能够还原 $\mathbb{E}_{z|x}[z]$ 的量，都可以用来还原无条件向量场与 score。此外，从数值计算与训练稳定性的角度来看，这种做法甚至可能更优。

一种常用选择是直接使用后验均值本身，它通常被称为**去噪器（denoiser）**。形式上，我们定义条件去噪器与边缘去噪器：

$$
\begin{aligned}
D_t(x|z) = z, \quad D_t(x) &= \int z\,\frac{p_t(x|z)\,p_{\text{data}}(z)}{p_t(x)}\,dz \\
&\overset{(i)}{=} \frac{1}{\dot{\alpha}_t\beta_t - \alpha_t\dot{\beta}_t}\left(\beta_t \boldsymbol{u}_t^{\text{target}}(x_t) - \dot{\beta}_t x_t\right).
\end{aligned}
\tag{43}
$$

其中步骤 (i) 的推导方式与命题 1 一致。去噪器具有非常直观的物理解释：它是在给定含噪数据 x 条件下，干净数据 z 的期望。

这类模型通常被称为**去噪扩散模型**，因为学习 D_t 和学习 $\boldsymbol{u}_t^{\text{target}}$ 在理论上是等价的。

思考问题：去噪器是否总能输出“干净”的数据样本？为什么能 / 不能？结果会依赖哪些因素？

下面的交互图把命题 1 与式 (43) 变成可以核对的数字。仍然取 Lecture 2 的一维三点玩具数据分布，$\alpha_t = t$, $\beta_t = 1 - t$：同一个 (t, x) 处，用两条不同的路线算同一个量，比较结果。

量	路线一	路线二
边缘速度 $u_t(x)$	式 (18)：1.380	式 (42)：1.380 两路线之差 < 1e-12
去噪器 $D_t(x)$	后验均值：1.090	式 (43)：1.090 两路线之差 < 1e-12

数据点	后验权重 w_k	conditional score (40)	条件速度 (20)
$z_1 = -2.0$	0.018	-5.600	-4.800
$z_2 = 1.0$	0.892	0.400	1.200
$z_3 = 2.6$	0.090	3.600	4.400
边缘（按 w_k 加权，式 (38)(18)）		0.580	1.380

时间 t = **0.50** （a_t = 1.000，b_t = 2.000）

位置 x = **0.40**

图例：路线一直接用式 (18) 与后验均值的定义；路线二先由式 (38) 把 conditional score 按后验权重加权得到 marginal score，再用式 (42) 算 $u_t(x)$，并把这个 u 代入式 (43) 算 $D_t(x)$。两条路线共用同一组后验权重，“两路线之差”只剩浮点误差（低于 1e-12）。

✦ 交互图 B · 命题 1 与式 (43) 的数值检验（三个数据点 $z_1 = -2.0$，$z_2 = 1.0$，$z_3 = 2.6$，先验 0.4 / 0.4 / 0.2；α_t=t，β_t=1−t）。拖动 t 与 x：上表对比 $u_t(x)$ 与去噪器 $D_t(x)$ 各自的两种算法，下表是各数据点的后验权重与 Conditional Score / 条件速度。

02. 基于 SDE 的采样

到目前为止，我们已经介绍了如何利用边缘向量场 $\boldsymbol{u}_t^{\text{target}}$ 构造常微分方程（ODE）的轨迹 X_t，使其服从目标概率路径 p_t。但该方法仅限于流模型。那扩散模型该如何处理？接下来我们借助 score function，将上述结论拓展到随机微分方程（SDE）。

2.1. SDE 扩展技巧

定理 17 · SDE 扩展技巧

如前文定义条件向量场 $\boldsymbol{u}_t^{\text{target}}(x|z)$ 与边缘向量场 $\boldsymbol{u}_t^{\text{target}}(x)$。对任意扩散系数 $\sigma_t \geq 0$，我们可以在原 ODE 动力学基础上增加随机动力学，构造如下 SDE：

$$\begin{aligned} X_0 &\sim p_{\text{init}}, \\ dX_t &= \boldsymbol{u}_t^{\text{target}}(X_t)\,dt + \frac{\sigma_t^2}{2}\nabla \log p_t(X_t)\,dt + \sigma_t\,dW_t \end{aligned} \tag{44}$$

$$dX_t = \left[\boldsymbol{u}_t^{\text{target}}(X_t) + \frac{\sigma_t^2}{2}\nabla \log p_t(X_t)\right] dt + \sigma_t\,dW_t \tag{45}$$

则有 $X_t \sim p_t \quad (0 \leq t \leq 1)$。特别地，该 SDE 的终端状态满足 $X_1 \sim p_{\text{data}}$。

可以看到，该随机动力学与朗之万动力学密切相关，可以理解为在保持边缘分布 p_t 不变的同时注入噪声。我们将在注记 20 中简要介绍朗之万动力学。

图 9 展示了定理 17 描述的动力学过程。可以观察到轨迹呈现锯齿状，体现 SDE 演化的随机性。但正如定理 17 所证明的，边缘分布 p_t 保持不变。该结论非常有意思：**即使网络训练完成之后，我们仍然可以任选扩散系数** $\sigma_t \geq 0$。理论上定理 17 对任意 σ_t 均成立。但实际应用中会存在两类误差：训练误差（神经网络无法完美拟合边缘向量场与 score function）与仿真误差（例如当 $\sigma_t \gg 0$ 时，算法 2 需要极小的步长，计算开销无法承受）。因此在实际中，对于一个固定的已训练模型，存在一个最优的 $\sigma_t \geq 0$，可通过实验确定 [23, 1, 28]。

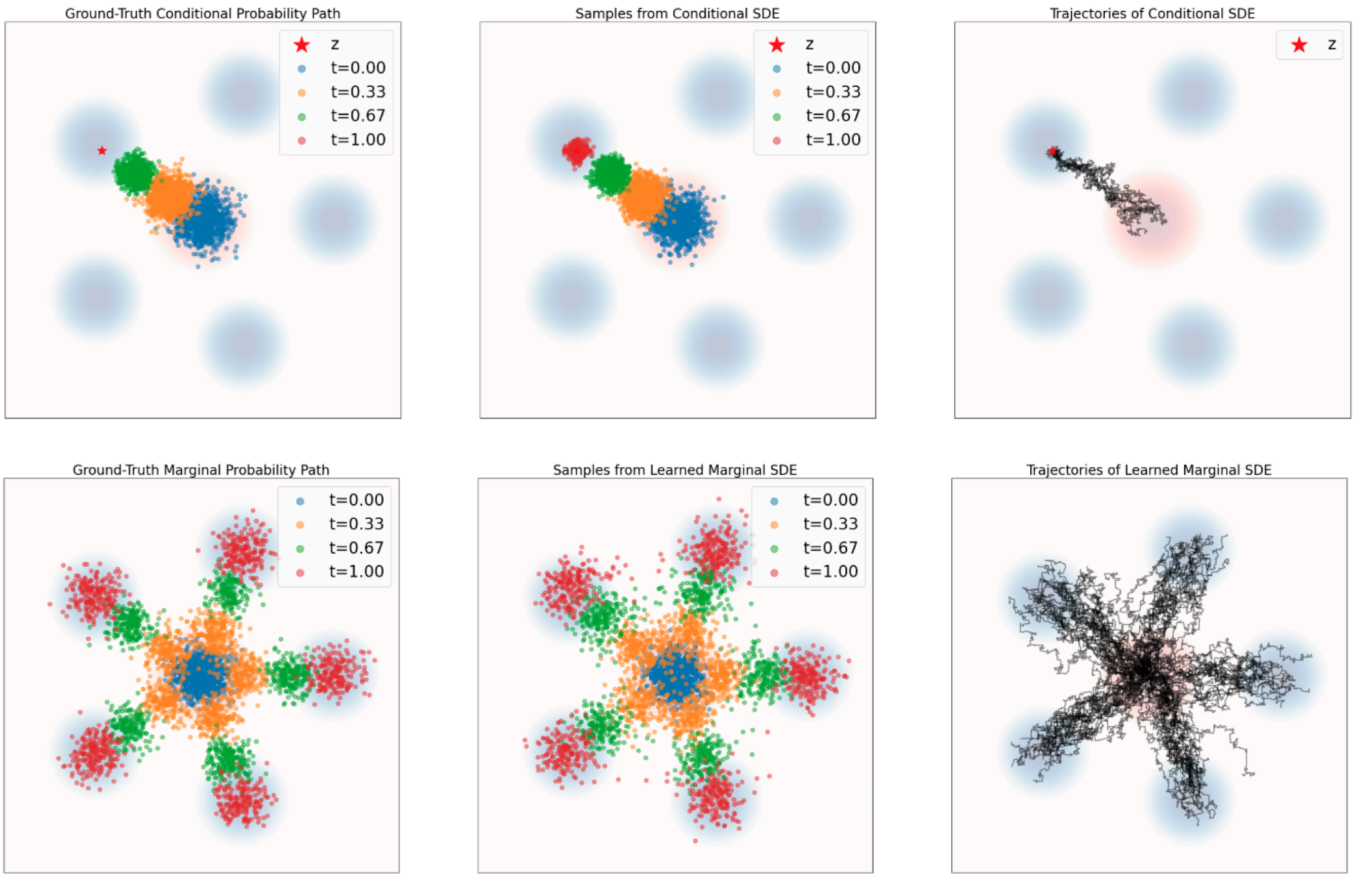
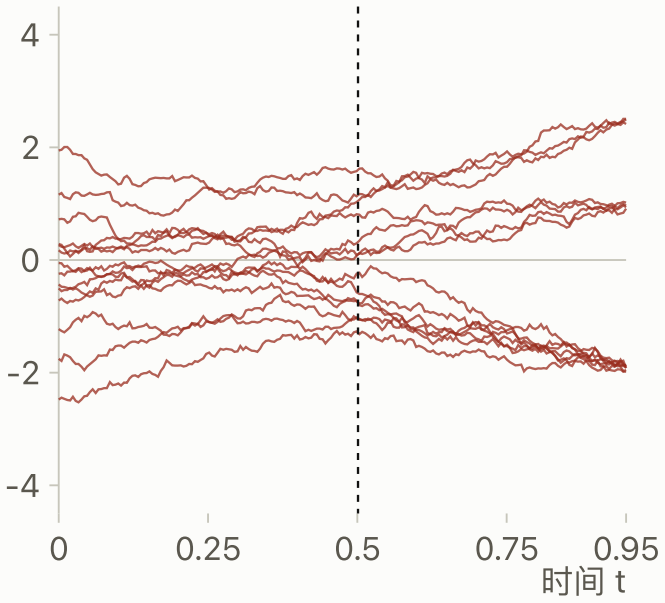


Figure 9: Illustration of Theorem 17. Simulating a probability path with SDEs. This repeats the plots from Figure 6 with SDE sampling using Equation (44). Data distribution p_{data} in blue background. Gaussian p_{init} in red background. Top row: Conditional path. Bottom row: Marginal probability path. As one can see, the SDE transports samples from p_{init} into samples from δ_z (for the conditional path) and to p_{data} (for the marginal path).

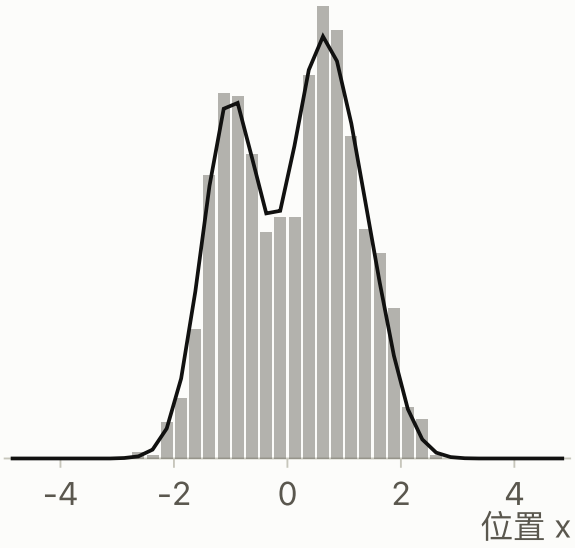
图 9. 定理 17 图示：用 SDE 模拟概率路径。这是上一讲图 6 在式 (44) 的 SDE 采样下的重复。蓝色背景为数据分布，红色背景为初始的高斯分布。上排为条件概率路径，下排为边缘概率路径。可以看到，SDE 把初始分布的样本输运到狄拉克分布 δ（条件路径，即单个数据点 z）与数据分布（边缘路径）。· 来源：MIT 6.S184 讲义

图 9 是二维的静态图。下面的交互图在一维三点玩具数据分布上（同上一讲，$\alpha_t = t$, $\beta_t = 1 - t$）按式 (44) 直接模拟 SDE，把扩散系数 σ 交给你：$\sigma = 0$ 时是光滑的 ODE，$\sigma > 0$ 时轨迹呈锯齿状，而右图中粒子在各时刻的分布与解析的边缘分布 p_t 基本一致。模拟终点取 $t = 0.95$：式 (20) 在 $\beta_t = 0$ 处无定义，而且 β_t 很小时固定步长的欧拉-丸山会失真（离线实测，终点取 0.98 且 σ 较大时偏差明显），这正对应上面说的第二类误差。

轨迹（σ = 0.60）



t = 0.50 时的粒子分布



扩散系数 σ = **0.60**（SDE）

时间 t = **0.50**

直方图与解析分布的总变差距离 = 0.046（1500 个粒子；用精确采样同样取 1500 个粒子，总变差距离也有约 0.02–0.05 的噪声）

图例：左图为 14 条粒子轨迹，虚线为当前时刻；右图灰色柱为粒子在各箱内的占比，黑线为解析边缘分布 p_t 在同一箱内的概率质量。σ 越大轨迹越抖，但各时刻的分布基本不变。模拟终点取 0.95：更接近 1 时 β_t 很小，固定步长的欧拉-丸山会失真（离线实测，终点取 0.98 且 σ 较大时偏差明显），这正是正文所说的仿真误差。

✦ 交互图 C · 同一条概率路径，任选 σ：一维三点玩具数据分布（$z_1 = -2.0$，$z_2 = 1.0$，$z_3 = 2.6$，先验 0.4 / 0.4 / 0.2），$\alpha_t = t$，$\beta_t = 1 - t$，按式 (44) 做欧拉-丸山模拟，终点取 0.95。

对于高斯概率路径，只要学习得到边缘向量场，就可以直接得到 score function。

例 18 · 高斯情形的 SDE 扩展技巧

由命题 1，对于高斯概率路径，我们可以将定理 17 中的 SDE 完全用 score function 表达：

$$\begin{aligned} X_0 &\sim p_{\text{init}}, \\ dX_t &= \left[\left(a_t + \frac{\sigma_t^2}{2}\right)\nabla \log p_t(X_t) + b_t X_t\right] dt + \sigma_t\, dW_t \end{aligned} \tag{46}$$

$$X_t \sim p_t \quad (0 \le t \le 1) \tag{47}$$

其中 a_t, b_t 的定义与命题 1 一致。把 marginal score 换成训练好的 score network，就得到实际采样时使用的 SDE（原讲义标注为 “Plugin score network”）：

$$dX_t = \left[\left(a_t + \frac{\sigma_t^2}{2}\right) s_t^\theta(X_t) + b_t X_t\right] dt + \sigma_t\, dW_t$$

2.2. 福克-普朗克方程

本节剩余部分将借助福克-普朗克方程（Fokker-Planck equation）证明定理 17，该方程将连续性方程从 ODE 拓展到 SDE。为此，我们先定义拉普拉斯算子 Δ。对标量场 $w_t : \mathbb{R}^d \to \mathbb{R}$：

$$\Delta w_t(x) = \sum_{i=1}^{d} \frac{\partial^2}{\partial x_i^2} w_t(x) = \operatorname{div}(\nabla w_t)(x). \tag{48}$$

定理 19 · 福克-普朗克方程（Fokker-Planck Equation）

设 p_t 为一条概率路径，考虑如下随机微分方程（SDE）：

$$X_0 \sim p_{\text{init}}, \quad dX_t = \boldsymbol{u}_t(X_t)\, dt + \sigma_t\, dW_t$$

则对所有 $0 \le t \le 1$，X_t 的分布为 p_t 的充要条件是福克-普朗克方程成立：

$$\partial_t p_t(x) = -\operatorname{div}\big(p_t \boldsymbol{u}_t\big)(x) + \frac{\sigma_t^2}{2}\Delta p_t(x), \quad \forall x \in \mathbb{R}^d,\ 0 \le t \le 1. \tag{49}$$

福克-普朗克方程的完整自包含证明见附录 B。注意：当 $\sigma_t = 0$ 时，福克-普朗克方程就退化为定理 11 的连续性方程。新增的拉普拉斯项 Δp_t 初看不易理解。熟悉物理的读者会发现，该项同样出现在热方程中（热方程本身就是福克-普朗克方程的特例），描述热量在介质中的扩散。我们这里引入的

是数学意义上的扩散过程（并非物理扩散），因此需要增加这个拉普拉斯项。接下来我们利用福克-普朗克方程证明定理 17。

2.3. 定理 17 的证明

根据定理 19，我们只需证明式 (44) 定义的 SDE 满足关于 p_t 的福克-普朗克方程，直接推导如下：

$$
\begin{aligned}
\partial_t p_t(x) &\overset{(i)}{=} -\operatorname{div}\left(p_t \boldsymbol{u}_t^{\text{target}}\right)(x) \\
&\overset{(ii)}{=} -\operatorname{div}\left(p_t \boldsymbol{u}_t^{\text{target}}\right)(x) - \frac{\sigma_t^2}{2}\Delta p_t(x) + \frac{\sigma_t^2}{2}\Delta p_t(x) \\
&\overset{(iii)}{=} -\operatorname{div}\left(p_t \boldsymbol{u}_t^{\text{target}}\right)(x) - \operatorname{div}\left(\frac{\sigma_t^2}{2}\nabla p_t\right)(x) \\
&\qquad + \frac{\sigma_t^2}{2}\Delta p_t(x) \\
&\overset{(iv)}{=} -\operatorname{div}\left(p_t \boldsymbol{u}_t^{\text{target}}\right)(x) - \operatorname{div}\left(p_t\left[\frac{\sigma_t^2}{2}\nabla \log p_t\right]\right)(x) \\
&\qquad + \frac{\sigma_t^2}{2}\Delta p_t(x) \\
&\overset{(v)}{=} -\operatorname{div}\left(p_t\left[\boldsymbol{u}_t^{\text{target}} + \frac{\sigma_t^2}{2}\nabla \log p_t\right]\right)(x) + \frac{\sigma_t^2}{2}\Delta p_t(x),
\end{aligned}
$$

其中：(i) 使用定理 11；(ii) 对同一项做加减恒等变形；(iii) 使用拉普拉斯算子的定义（式 (48)）；(iv) 利用恒等式 $\nabla \log p_t = \frac{\nabla p_t}{p_t}$；(v) 使用散度算子的线性性质。上述推导证明式 (44) 定义的 SDE 满足 p_t 对应的福克-普朗克方程。根据定理 19，可得到 $X_t \sim p_t$ $(0 \le t \le 1)$，即为待证结论。

2.4. 朗之万动力学

注记 20（选读）· 朗之万动力学（Langevin Dynamics）

当概率路径为常数分布，也就是 $p_t = p$（p 为固定分布）时，上面的构造就退化为一个经典特例。此时令 $\boldsymbol{u}_t^{\text{target}} = 0$，可以得到 SDE：

$$dX_t = \frac{\sigma_t^2}{2} \nabla \log p(X_t)\, dt + \sigma_t\, dW_t \tag{50}$$

这就是大家熟知的**朗之万动力学**。p_t 为常数意味着 $\partial_t p_t(x) = 0$。直接由定理 17 可推得：该动力学满足静态路径 $p_t = p$ 对应的福克-普朗克方程。因此可以得到结论：p 是朗之万动力学的平稳分布：

$$X_0 \sim p \implies X_t \sim p \quad (t \geq 0).$$

和很多马尔可夫过程一样，在较为宽松的条件下，该动力学会收敛到平稳分布 p。也就是说，若初始分布 $X_0 \sim p' \neq p$，记此时 X_t 的分布为 p'_t，则在弱条件下有 $p'_t \to p$。该特性让朗之万动力学极具实用价值，它也是分子动力学模拟、贝叶斯统计与自然科学中大量马尔可夫链蒙特卡洛（MCMC）方法的基础。特别地，当 p 为高斯分布时，朗之万动力学退化为奥恩斯坦–乌伦贝克过程（Ornstein-Uhlenbeck process），这也是早期扩散模型的理论基础。

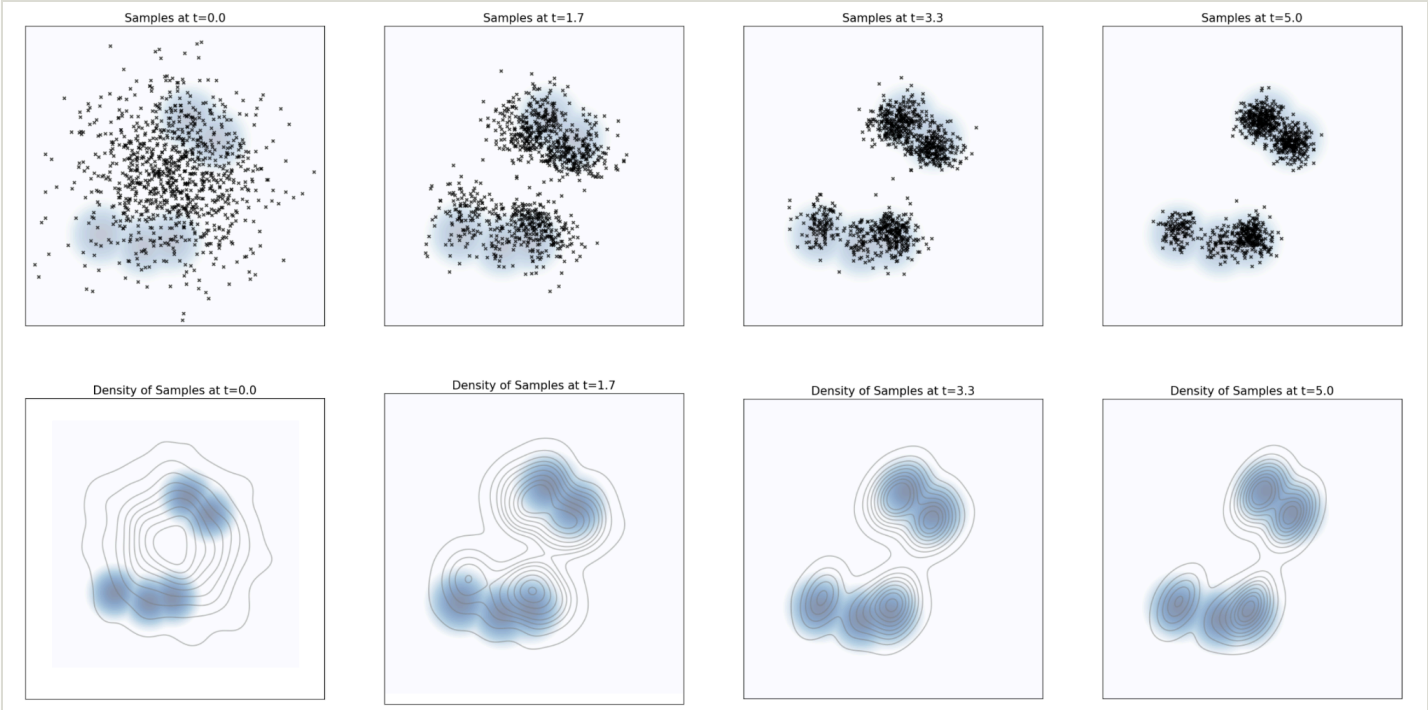


Figure 10: Top row: Particles evolving under the Langevin dynamics given by Equation (50), with $p(x)$ taken to be a Gaussian mixture with 5 modes. Bottom row: A kernel density estimate of the same samples shown in the top row. As one can see, the distribution of samples converges to the equilibrium distribution p (blue background colour).

图 10. 上排：朗之万动力学（式 (50)）下粒子的演化，p(x) 取为含 5 个峰的高斯混合；下排：同一批样本的核密度估计。可以看到，样本分布收敛到平稳分布 p（蓝色背景）。· 来源：MIT 6.S184 讲义

2.5. GLASS 流

注记 21（选读）· GLASS 流：基于 ODE 的随机演化

相比于 ODE，SDE 采样最突出的特点是演化具有随机性：初始点 X_0 无法唯一确定 $t > 0$ 时刻的 X_t。但一个有意思的结论：借助一种叫做 GLASS 流 [20] 的简单采样技巧，**仅依靠 ODE 也可以实现完全相同的随机转移**。该方法既可以利用 SDE 的随机特性（例如用于搜索算法），同时保留 ODE 的计算高效性。

03. Score Matching

接下来我们需要说明如何学习marginal score function $\nabla \log p_t(x)$。当然，对于高斯概率路径，我们可以直接利用命题 1 对 $\boldsymbol{u}_t^{\text{target}}(x)$ 做变换得到。但一般情况该如何处理？事实上，我们也可以直接学习marginal score function。为了近似 marginal score $\nabla \log p_t$，我们使用一个神经网络，称为

score network $s_{\theta_t} : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$。

3.1. Score Matching 损失

和前文思路一致，我们可以定义 score matching 损失与 conditional score matching 损失：

$$\mathcal{L}_{\text{SM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)}\left[\left\| s_{\theta_t}(x) - \nabla \log p_t(x) \right\|^2\right] \quad \triangleright \text{ score matching 损失}$$

← 左右滑动查看 →

$$\mathcal{L}_{\text{CSM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)}\left[\left\| s_{\theta_t}(x) - \nabla \log p_t(x|z) \right\|^2\right] \quad \triangleright \text{ conditional score ma}$$

← 左右滑动查看 →

二者的区别在于：前者使用 marginal score $\nabla \log p_t(x)$，后者使用 conditional score $\nabla \log p_t(x|z)$。和之前一样，我们的理想目标是最小化 score matching 损失，但由于 $\nabla \log p_t(x)$ 未知，无法直接优化。不过同样，conditional score matching 损失是一个可求解的替代方案。

3.2. 定理 22：两种损失只差一个常数

定理 22

score matching 损失与 conditional score matching 损失仅相差一个常数：

$$\mathcal{L}_{\text{SM}}(\theta) = \mathcal{L}_{\text{CSM}}(\theta) + C$$

其中常数 C 与参数 θ 无关。因此二者梯度相等：

$$\nabla_\theta \mathcal{L}_{\text{SM}}(\theta) = \nabla_\theta \mathcal{L}_{\text{CSM}}(\theta)$$

特别地，对于最优参数 θ^*，满足 $s_{\theta_t^*} = \nabla \log p_t$。

证明：注意 $\nabla \log p_t$ 的表达式（式 (38)）与 $\boldsymbol{u}_t^{\text{target}}$ 的表达式（式 (18)）形式完全相同。因此只需将定理 12 证明中的 $\boldsymbol{u}_t^{\text{target}}$ 替换为 $\nabla \log p_t$，即可得到本定理的证明。

Algorithm 6 Score Matching 训练流程（一般情形，Score Matching Training Procedure · General）

输入：由数据样本 $z \sim p_{\text{data}}$ 构成的数据集，score network s_t^θ

1: **for** 每个 mini-batch 的数据 **do**
2: 从数据集中采样一个数据样本 z
3: 采样随机时间 $t \sim \text{Unif}_{[0,1]}$
4: 采样 $x \sim p_t(\cdot|z)$
5: 计算损失

$$\mathcal{L}(\theta) = \left\| s_t^\theta(x) - \nabla \log p_t(x|z) \right\|^2$$

6: 对 $\mathcal{L}(\theta)$ 做梯度下降，更新模型参数 θ
7: **end for**

✦ Algorithm 6 · Score Matching 训练流程（一般情形，据原讲义重排）。

3.3. 例 23：去噪扩散模型

例 23 · 去噪扩散模型：高斯概率路径下的 Score Matching

我们针对 $p_t(x|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$ 的实例，写出 denoising score matching 损失。根据式 (40) 推导得到，conditional score $\nabla \log p_t(x|z)$ 的表达式为：

$$\nabla \log p_t(x|z) = -\frac{x - \alpha_t z}{\beta_t^2}. \tag{51}$$

将该式代入，conditional score matching 损失变为：

$$\begin{aligned}
\mathcal{L}_{\text{CSM}}(\theta) &= \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, x\sim p_t(\cdot|z)} \left[\left\| s_{\theta,t}(x) + \frac{x - \alpha_t z}{\beta_t^2} \right\|^2 \right] \\
&\overset{(i)}{=} \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, \varepsilon\sim\mathcal{N}(0,I_d)} \left[\left\| s_{\theta,t}(\alpha_t z + \beta_t \varepsilon) + \frac{\varepsilon}{\beta_t} \right\|^2 \right] \\
&= \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, \varepsilon\sim\mathcal{N}(0,I_d)} \left[\frac{1}{\beta_t^2} \left\| \beta_t s_{\theta,t}(\alpha_t z + \beta_t \varepsilon) + \varepsilon \right\|^2 \right]
\end{aligned}$$

其中步骤 (i) 代入式 (28)，把 x 替换为 $\alpha_t z + \beta_t \varepsilon$。可以看到，网络 $s_{\theta,t}$ 的本质是学习预测用来污染样本 z 的噪声。这也是该训练损失被称为 denoising score matching 的原因。

人们很快发现：当 $\beta_t \approx 0$ 时，上述损失会出现数值不稳定的问题（也就是说 denoising score matching 需要加入足够强度的噪声才能正常工作）。因此在早期去噪扩散概率模型相关工作（DDPM，文献 [17]）中，研究者提出舍弃损失中的常数项 $\frac{1}{\beta_t^2}$，并将 score network $s_{\theta,t}$ 重参数化为噪声预测网络 $\varepsilon_{\theta,t} : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$，变换关系如下：

$$-\beta_t s_{\theta,t}(x) = \varepsilon_{\theta,t}(x) \implies \mathcal{L}_{\text{DDPM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},\, z\sim p_{\text{data}},\, \varepsilon\sim\mathcal{N}(0,I_d)}\left[\left\|\varepsilon_{\theta,t}(\alpha_t z + \beta_t \varepsilon) - \varepsilon\right\|^2\right]$$

← 左右滑动查看 →

和前面一致，网络 $\varepsilon_{\theta,t}$ 的核心目标就是预测用来污染原始样本 z 的噪声。算法 4 总结了该训练流程。

Algorithm 4 高斯概率路径的 Score Matching 训练流程（Score Matching Training Procedure for Gaussian probability path）

输入：由数据样本 $z \sim p_{\text{data}}$ 构成的数据集，score network s_t^θ 或噪声预测网络 ϵ_t^θ

1: **for** 每个 mini-batch 的数据 **do**
2: 从数据集中采样一个数据样本 z
3: 采样随机时间 $t \sim \text{Unif}_{[0,1]}$
4: 采样噪声 $\epsilon \sim \mathcal{N}(0, I_d)$
5: 设 $x_t = \alpha_t z + \beta_t \epsilon$ ◂ 一般情形：$x_t \sim p_t(\cdot|z)$
6: 计算损失 ◂ 一般情形：$= \left\|s_t^\theta(x_t) - \nabla \log p_t(x_t|z)\right\|^2$

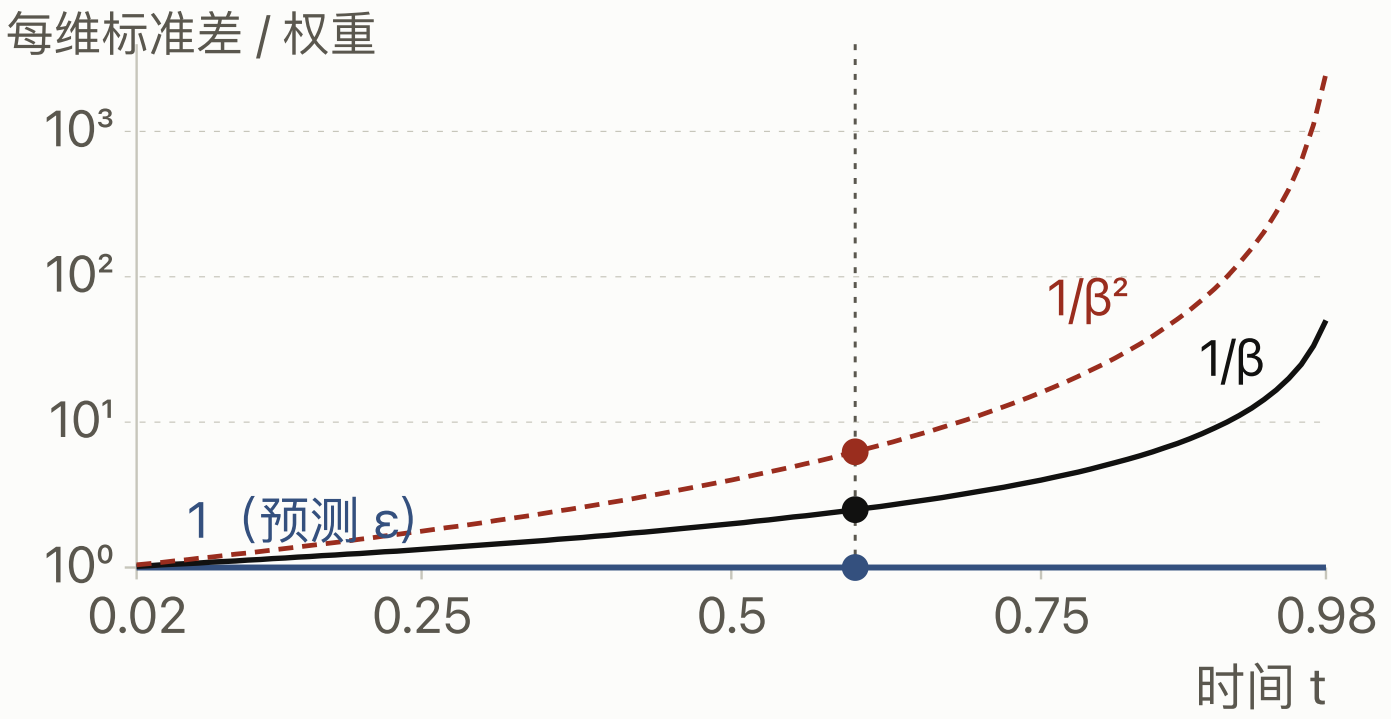
$$\mathcal{L}(\theta) = \left\| s_t^\theta(x_t) + \tfrac{\epsilon}{\beta_t} \right\|^2$$

或者：$\mathcal{L}(\theta) = \left\|\epsilon_t^\theta(x_t) - \epsilon\right\|^2$

7: 对 $\mathcal{L}(\theta)$ 做梯度下降，更新模型参数 θ
8: **end for**

✦ Algorithm 4 · 高斯概率路径的 Score Matching 训练流程（据原讲义重排；右侧批注为原讲义对应一般情形的写法）。

下面的交互图把例 23 所说的“数值不稳定”画成数字（本文补充）：取 $\alpha_t = t$, $\beta_t = 1 - t$，随 t 增大，β_t 趋近 0，直接回归 $-\varepsilon/\beta_t$ 的目标每一维的标准差为 $1/\beta_t$，迅速变大；而回归 ε 的目标每一维的标准差恒为 1。



时间 t = **0.60** （$\beta_t = 0.40$）

回归 $-\varepsilon/\beta_t$ 的目标：每维标准差 2.50；回归 ε 的目标：每维标准差 1；损失权重 $1/\beta_t^2 = 6.25$。

图例：纵轴为对数坐标。黑线为 score 目标 $-\varepsilon/\beta_t$ 的每维标准差 $1/\beta_t$，蓝线为噪声预测目标 ε 的每维标准差（恒为 1），红色虚线为例 23 损失中的权重 $1/\beta_t^2$。t 越接近 1，β_t 越接近 0，黑线与蓝线之比（即 $1/\beta_t$）和红色权重都迅速增大，这是对例 23 所说"$\beta_t \approx 0$ 时数值不稳定"的一个量化图景（本文补充，原讲义未展开）。

✦ 交互图 D · 为什么要舍去 $1/\beta_t^2$（$\alpha_t = t$，$\beta_t = 1 - t$）。拖动 t：对数纵轴上比较 score 目标、噪声预测目标与损失权重。

3.4. 小结 24：Score Function、Score Matching 与随机采样

小结 24 · Score Function、Score Matching 与随机采样

设 $p_t(x|z)$、$p_t(x)$ 分别为条件概率路径与边缘概率路径。conditional score function 定义为 $\nabla \log p_t(x|z)$，marginal score function 定义为 $\nabla \log p_t(x)$。对任意扩散系数 $\sigma_t \geq 0$，下述 SDE 的轨迹将服从该概率路径：

$$X_0 \sim p_{\text{init}}, \quad dX_t = \left[\boldsymbol{u}_t^{\text{target}}(X_t) + \frac{\sigma_t^2}{2} \nabla \log p_t(X_t) \right] dt + \sigma_t \, dW_t \tag{52}$$

$$\Rightarrow X_t \sim p_t \quad (0 \leq t \leq 1) \tag{53}$$

其中 $\boldsymbol{u}_t^{\text{target}}(x)$ 仍是前文定义的边缘向量场（见式 (18)）。

Score Matching

为学习marginal score function $\nabla \log p_t(x)$，我们使用 score network $\boldsymbol{s}_t^\theta$，并通过 denoising score matching 来训练：

$$\mathcal{L}_{\text{CSM}}(\theta) = \mathbb{E}_{z \sim p_{\text{data}},\, t \sim \text{Unif},\, x \sim p_t(\cdot|z)} \left[\left\| \boldsymbol{s}_t^\theta(x) - \nabla \log p_t(x|z) \right\|^2 \right] \tag{54}$$

（denoising score matching 损失）

高斯概率路径

对于最重要的高斯概率路径 $p_t(x|z) = \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d)$，无需分开训练 $\boldsymbol{s}_t^\theta$ 和 $\boldsymbol{u}_t^\theta$，二者可以通过下式互相转换：

$$\boldsymbol{u}_t^\theta(x) = a_t \boldsymbol{s}_t^\theta(x) + b_t x, \quad a_t = \left(\frac{\beta_t^2 \dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t \right), \quad b_t = \frac{\dot{\alpha}_t}{\alpha_t}$$

训练完成后，对任意扩散系数 $\sigma_t \geq 0$，可以模拟如下 SDE：

$$dX_t = \left[\left(1 + \frac{\sigma_t^2}{2a_t} \right) \boldsymbol{u}_t^\theta(X_t) - \frac{\sigma_t^2 b_t}{2a_t} X_t \right] dt + \sigma_t \, dW_t \tag{55}$$

$$dX_t = \left[\left(a_t + \frac{\sigma_t^2}{2} \right) \boldsymbol{s}_t^\theta(X_t) + b_t X_t \right] dt + \sigma_t \, dW_t \tag{56}$$

从而得到近似样本 $X_1 \sim p_{\text{data}}$。可以通过实验寻找最优的 $\sigma_t \geq 0$。其中 a_t 取命题 1 之后“校注”中的写法；式 (55) 与式 (56) 互为同一 SDE 的两种写法，只用到 $\boldsymbol{u}_t^\theta = a_t \boldsymbol{s}_t^\theta + b_t x$，与 a_t 的具体形式无关。

结语：向量场、Score、去噪器与噪声预测对照

下表把正文中散落的事实并排放在一起（均针对高斯概率路径）：

表 1. 高斯概率路径下四种"学习对象"的对照

学习对象	与向量场的换算	训练损失与正文中的说明
向量场 $\boldsymbol{u}_t^\theta$	基准	本讲的起点：边缘向量场 $\boldsymbol{u}_t^{\text{target}}$ 构造 ODE 的轨迹 X_t（训练方式见上一讲，本讲正文未重述）
score $\boldsymbol{s}_t^\theta$	$\boldsymbol{u}_t^\theta = a_t \boldsymbol{s}_t^\theta + b_t x$（式 (42)、小结 24）	conditional score matching 损失（式 (54)），即 denoising score matching；定理 22：与 score matching 损失只差常数 C，梯度相等
噪声预测 $\varepsilon_{\theta,t}$	$-\beta_t \boldsymbol{s}_{\theta,t} = \varepsilon_{\theta,t}$（例 23）	$\mathcal{L}_{\text{DDPM}}$：舍去 $1/\beta_t^2$ 后回归 ε；$\beta_t \approx 0$ 时 denoising score matching 数值不稳定
去噪器 D_t	$D_t(x) = \frac{\beta_t \boldsymbol{u}_t^{\text{target}}(x) - \dot{\beta}_t x}{\dot{\alpha}_t \beta_t - \alpha_t \dot{\beta}_t}$（式 (43)）	正文未给出专门的损失。D_t 是后验均值 $\mathbb{E}[z \mid x]$；学 D_t 与学 $\boldsymbol{u}_t^{\text{target}}$ 理论上等价（注记 16）

从表中可以看出：对高斯概率路径，向量场、score 与去噪器可以互相换算，噪声预测是 score 的重参数化。训练完成后，再任选扩散系数 $\sigma_t \geq 0$，按式 (55) 或式 (56) 模拟 SDE，就得到近似服从数据分布的样本。

Made with beautiful-article · knuth theme