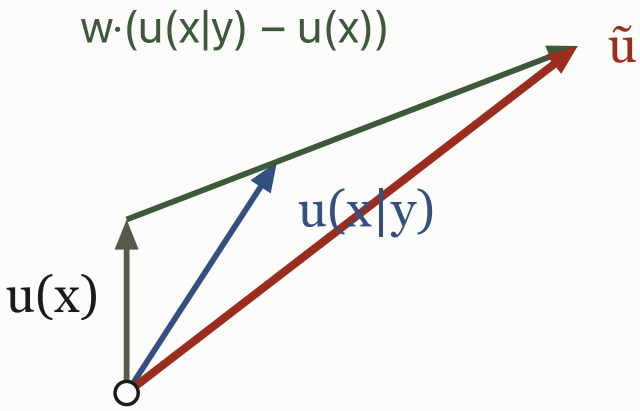
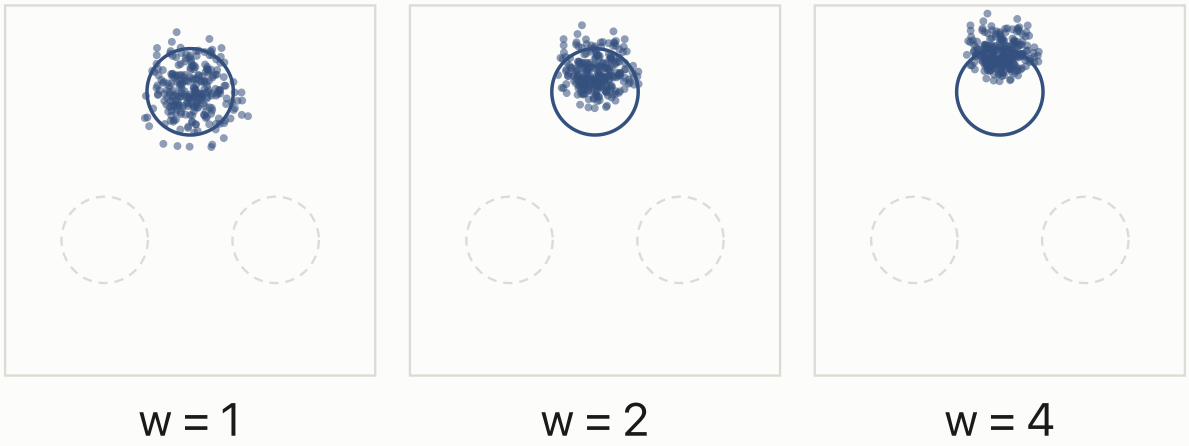
FLOW MATCHING & DIFFUSION · NOTES 04

朝提示词多走几步

Classifier-Free Guidance 的几何直觉



$$\tilde{u} = (1-w)\cdot u(x) + w\cdot u(x|y)$$



目录

01 基础引导（Vanilla Guidance）

1.1 无引导与引导

1.2 引导扩散模型与引导流模型

1.3 训练：引导条件流匹配损失

02 从分类器引导到无分类器引导

2.1 为什么基础引导不够

2.2 分类器引导（Classifier Guidance）

2.3 无分类器引导（CFG）

2.4 对任意概率路径都成立

03 CFG 的训练、采样与启发式

3.1 训练：以概率 η 丢弃标签

3.2 小结 27：流模型的无分类器引导

3.3 推理阶段：用增强向量场采样

3.4 CFG 是启发式方法

Classifier-Free Guidance：把有、无提示词两个向量场之差放大 w 倍

读完能写出 CFG 的训练算法（含丢弃标签）与采样式，并说清它为什么等价于放大分类器的梯度，又为什么只是一种启发式

课程： MIT 6.S184 Flow Matching & Diffusion Models　类型： 个人学习笔记　日期： 2026-10

前几讲的生成模型都是无引导的：只会随机生成一个样本。本讲加入提示词 y，先给出把 y 直接输入网络的基础引导，再说明它为什么不够，最后从分类器引导推出无分类器引导（classifier-free guidance，CFG）。

三句话读懂本讲

1. 基础引导把提示词 y 输入网络，用联合样本 (z, y) 训练引导条件流匹配损失；理论上它能从数据的条件分布采样，但实验里样本与提示词的匹配并不理想。
2. 引导向量场等于无条件向量场加上 $a_t \nabla \log p_t(y|x)$。放大这一项（分类器引导）就等价于 $(1-w)\cdot u(x) + w\cdot u(x|y)$（CFG），不再需要单独训练分类器。
3. CFG 用同一个网络同时学条件与无条件向量场：训练时以概率 η 把 y 换成空标签 ∅，推理时取 $w > 1$。它是启发式，$w > 1$ 时样本分布不再等于数据的条件分布，但对齐效果极好，常取 $w \geq 4$。

01. 基础引导（Vanilla Guidance）

1.1. 无引导与引导

到目前为止，我们讨论的生成模型都是**无引导（unguided）**的。例如图像模型只会随机生成一张图像。从数学角度来说，这代表模型从无条件数据分布 $p_{\text{data}}(z)$ 中采样。但绝大多数场景下，我们的目标并不是随便生成一个物体，而是基于额外信息来生成指定类型的物体。换言之，我们希望**引导模型**生成特定类别的样本。举个例子：图像生成模型接收文本提示词 y，然后生成符合文本提示词 y 的图像 x。正如前几讲第 1 节所讨论的，这意味着我们想要从条件分布 $p_{\text{data}}(z|y)$ 采样，也就是以 y 为条件的引导后的数据分布。本节将对此展开讨论。

注记 25 · 术语说明

为了避免符号与术语冲突（前文的“条件”一词是指以 $z \sim p_{\text{data}}$ 为条件，用于条件概率路径与条件向量场），我们专门使用**引导（guided）**一词，特指以文本提示词这类 y 作为条件。

1.2. 引导扩散模型与引导流模型

首先介绍构建条件生成模型的“标准”方式。简单来说：**训练和推理阶段都把提示词 y 输入网络，其余流程和之前保持一致**。下面给出形式化定义。

设条件变量（提示词）y 属于空间 $\mathcal{Y}$。例如当 y 是文本提示词时，$\mathcal{Y}$ 是所有文本构成的空间；当 y 是离散类别标签时，$\mathcal{Y}$ 为离散空间。对 $\mathcal{Y}$ 不做额外约束。

定义 · 引导扩散模型

引导扩散模型由神经网络参数化的引导向量场 $\boldsymbol{u}_t^\theta(\cdot|y)$，以及时变扩散系数 σ_t 共同构成：

- 神经网络：$\boldsymbol{u}^\theta : \mathbb{R}^d \times \mathcal{Y} \times [0,1] \to \mathbb{R}^d, \quad (x, y, t) \mapsto \boldsymbol{u}_t^\theta(x|y)$
- 固定扩散系数：$\sigma_t : [0,1] \to [0, \infty), \quad t \mapsto \sigma_t$

对比小结 7 可以看到：我们额外把输入 $y \in \mathcal{Y}$ 作为引导信息传入 $\boldsymbol{u}_t^\theta$。

对任意 $y \in \mathcal{Y}$，模型采样流程如下：

1. 初始化：$X_0 \sim p_{\text{init}}$ ▶ 从简单分布（如高斯分布）初始化
2. 仿真：$dX_t = \boldsymbol{u}_t^\theta(X_t|y)\,dt + \sigma_t\,dW_t$ ▶ 从 $t=0$ 到 $t=1$ 仿真 SDE
3. 目标：$X_1 \sim p_{\text{data}}(\cdot|y)$ ▶ 期望 X_1 服从条件分布 $p_{\text{data}}(\cdot|y)$

当 $\sigma_t = 0$ 时，该模型称为**引导流模型（guided flow model）**。下文我们主要在流匹配与流模型框架下讨论，简化推导；但所有结论同样适用于一般 SDE 扩散模型。

1.3. 训练：引导条件流匹配损失

接下来讨论：如何训练引导流模型 $\boldsymbol{u}_t^\theta(x|y)$？一个简单思路：固定提示词 y，把数据分布取为 $p_{\text{data}}(x|y)$。此时问题退化为前面的无条件生成问题，我们可以用**条件流匹配损失**：

$$\mathcal{L} = \mathbb{E}_{z \sim p_{\text{data}}(\cdot|y),\, x \sim p_t(\cdot|z)} \left\| \boldsymbol{u}_t^\theta(x|y) - \boldsymbol{u}_t^{\text{target}}(x|z) \right\|^2 \tag{57}$$

注意：标签 y **不影响**条件概率路径 $p_t(\cdot|z)$ 和条件目标向量场 $\boldsymbol{u}_t^{\text{target}}(x|z)$（当然理论上也可以设计成依赖 y）。

把期望对所有 y 做展开，得到**引导条件流匹配损失**：

$$\mathcal{L}_{\text{guidedCFM}}(\theta) = \mathbb{E}_{(z,y)\sim p_{\text{data}}(z,y),\, t\sim\text{Unif}[0,1],\, x\sim p_t(\cdot|z)} \left\| \boldsymbol{u}_t^{\theta}(x|y) - \boldsymbol{u}_t^{\text{target}}(x|z) \right\|^2 \tag{58}$$

式 (58) 的引导损失和前文式 (26) 的无条件损失最核心的区别：这里采样的是联合样本 $(z, y) \sim p_{\text{data}}$，而不是仅采样 $z \sim p_{\text{data}}$。原因是此时的数据分布是联合分布，例如图像 z 和文本提示词 y 的联合分布。工程上，对应 PyTorch 实现时，Dataloader 需要同时返回成对的 (z, y) 批次数据。

02. 从分类器引导到无分类器引导

2.1. 为什么基础引导不够

理论上，基础引导（vanilla guidance）应当能够忠实实现 $p_{\text{data}}(\cdot|y)$ 的采样生成。但实验很快发现：采用该方法生成的图像样本，和目标提示词 y 的匹配度并不理想（见图 11）。造成该现象的原因有很多：模型欠拟合（也就是没能学到真实的边缘向量场），或是数据本身存在缺陷（例如互联网爬取的图文配对数据存在大量标注错误）。



Figure 11: Image generation with prompt/class y ="corgi dog". Left: samples generated with vanilla guidance - the images do not fit well to the prompt. Right: samples generated with classifier guidance and $w = 4$. As shown, classifier-free guidance improves the adherence to the prompt. Figure taken from [18].

图 11. 以提示词（类别）y = "corgi dog" 生成图像。左：基础引导的样本，与提示词匹配不佳；右：w = 4 的样本，与提示词贴合得更好。校注：图中原文把右列写作 classifier guidance，但按正文与文献 [18]，应为 classifier-free guidance。 · 来源：文献 [18]，MIT 6.S184 讲义

因此，为了生成和提示词贴合度更高的样本，我们需要一种手段**人为强化提示词 y 的约束作用**。实现该目标的主流技术就是**无分类器引导（classifier-free guidance）**，它被广泛应用于当前 SOTA 扩散模型；下面我们先从**分类器引导（classifier guidance）**入手介绍。

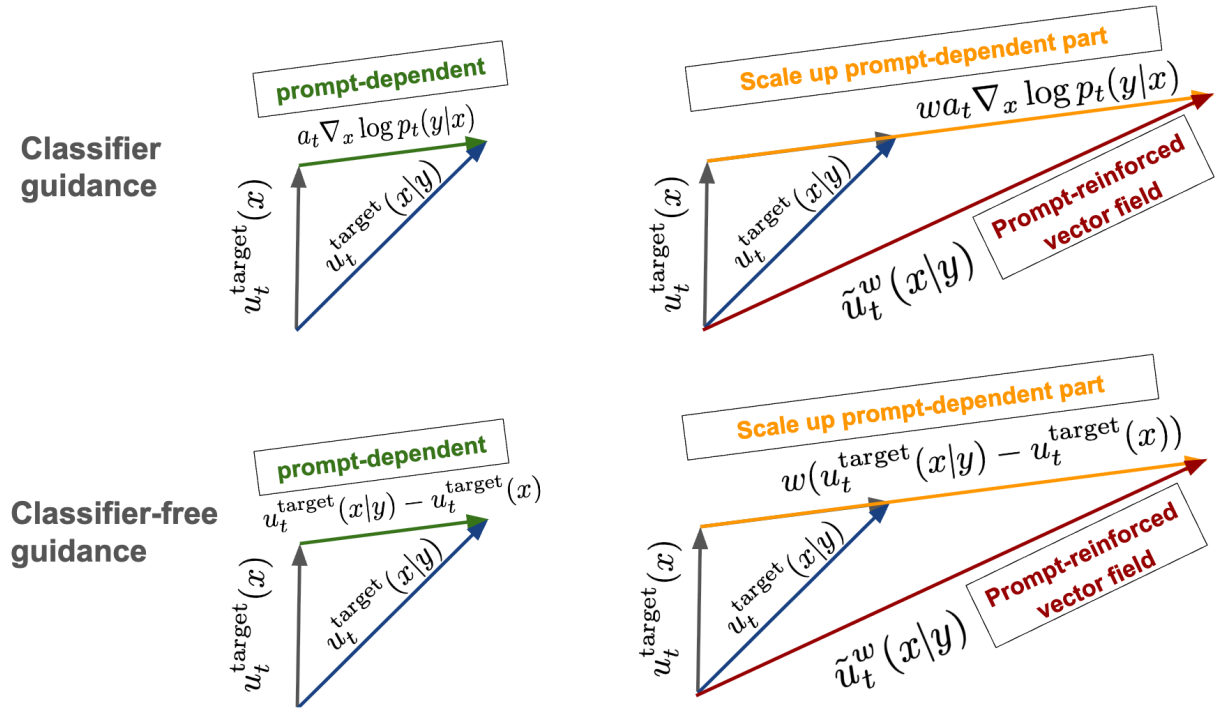


Figure 12: Illustration of classifier and classifier-free guidance. Classifier guidance decomposes the guided vector field $u_t^{\text{target}}(x|y)$ and the gradient of a classifier $\log p_t(y|x)$ and scales up the classifier with guidance scale $w > 1$. Classifier-free guidance scales up the difference between both vector fields, thereby achieving the same effect but without having to train a separate classifier model.

图 12. 分类器引导与无分类器引导的示意。分类器引导把引导目标向量场 u(x|y) 分解成无条件向量场与分类器的梯度 log p(y|x)，并用引导尺度 w > 1 放大分类器的部分；无分类器引导放大的是两个向量场之差，效果相同，但不需要另外训练分类器模型。 · 来源：MIT 6.S184 讲义

2.2. 分类器引导（Classifier Guidance）

为简化讨论，本节聚焦高斯概率路径场景。回顾式 (15)，高斯条件概率路径定义为

$$p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$$

其中噪声调度 α_t, β_t 连续可微、单调，并且满足边界条件：$\alpha_0 = \beta_1 = 0$, $\alpha_1 = \beta_0 = 1$。再回顾命题 1，我们可以利用引导 **score function** $\nabla \log p_t(x|y)$，将引导目标向量场改写为：

$$\boldsymbol{u}_t^{\text{target}}(x|y) = a_t \nabla \log p_t(x|y) + b_t x \tag{59}$$

注意 $p_t(x|y)$ 是条件密度，因此可以利用贝叶斯公式改写引导 score：

$$p_t(x|y) = \frac{p_t(x)\, p_t(y|x)}{p_t(y)} \tag{60}$$

对 x 求梯度：

$$\begin{aligned} \nabla \log p_t(x|y) &= \nabla \log \left(\frac{p_t(x)\, p_t(y|x)}{p_t(y)} \right) \\ &= \nabla \log p_t(x) + \nabla \log p_t(y|x) \end{aligned} \tag{61}$$

注：梯度 ∇ 是对变量 x 求导，$\log p_t(y)$ 和 x 无关，所以 $\nabla \log p_t(y) = 0$。

代入式 (59) 得到：

$$\begin{aligned} \boldsymbol{u}_t^{\text{target}}(x|y) &= b_t x + a_t \big(\nabla \log p_t(x) + \nabla \log p_t(y|x) \big) \\ &= \boldsymbol{u}_t^{\text{target}}(x) + a_t \nabla \log p_t(y|x). \end{aligned}$$

观察这个式子：**引导后的目标向量场 = 无条件向量场 + 引导变量 y 的似然梯度项**。实验中发现生成图像和提示词匹配不足，于是很自然想到：**放大 $\nabla \log p_t(y|x)$ 这一项的贡献**，得到增强后的向量场：

$$\tilde{\boldsymbol{u}}_t(x|y) = \boldsymbol{u}_t^{\text{target}}(x) + w\, a_t \nabla \log p_t(y|x) \tag{62}$$

式 (62) 即**分类器引导（classifier guidance）**，其中 $w > 1$ 称为**引导权重（guidance scale）**。

如何学习 $\log p_t(y|x)$？可以把它看作**带噪数据上的分类器**：给定带噪样本 x，输出 y 的对数似然。我们可以直接用监督学习训练这个分类器。这就是**分类器引导（classifier guidance）**[11, 43]（示意图见图 12）。

分类器引导后来基本被无分类器引导取代，因此不再深入展开；但正如下面会看到的，它是无分类器引导的理论基础。最后注意：这是一种启发式操作。当 $w \neq 1$ 时，$\tilde{\boldsymbol{u}}_t(x|y) \neq \boldsymbol{u}_t^{\text{target}}(x|y)$，也就是说这个增强后的向量场**不再是真实的条件目标向量场**。

2.3. 无分类器引导（CFG）

虽然分类器引导在原理上可行，但存在不少难点：首先，我们需要并行训练一个分类器和流 / 扩散模型——也就是要维护两个网络，而不是一个。其次，如果 y 是高维条件，例如文本提示词而不只是类别标签，那么 $p_t(y|x)$ 会非常难以学习，梯度 $\nabla \log p_t(y|x)$ 也很难获取。为此，研究者提出了无

分类器引导（**classifier-free guidance**）。

无分类器引导能够实现和分类器引导理论上等价的效果，且**不需要单独训练一个分类器**。我们再次利用等式：

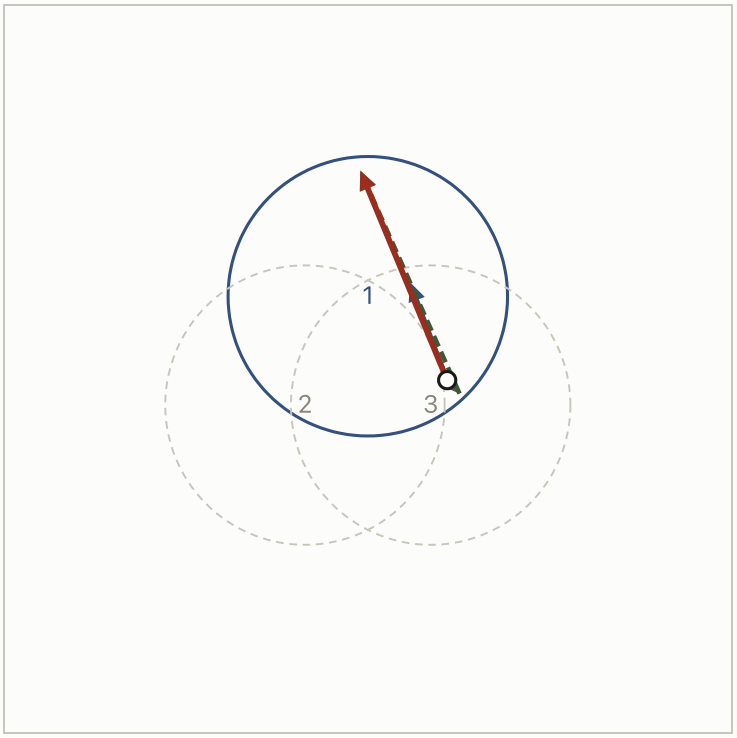
$$\nabla \log p_t(x|y) = \nabla \log p_t(x) + \nabla \log p_t(y|x)$$

对增强向量场做推导：

$$\begin{aligned}
\tilde{\boldsymbol{u}}_t(x|y) &= \boldsymbol{u}_t^{\text{target}}(x) + w a_t \nabla \log p_t(y|x) \\
&= \boldsymbol{u}_t^{\text{target}}(x) + w a_t \big(\nabla \log p_t(x|y) - \nabla \log p_t(x)\big) \\
&= \boldsymbol{u}_t^{\text{target}}(x) - \big(w b_t x + w a_t \nabla \log p_t(x)\big) + \big(w b_t x + w a_t \nabla \log p_t(x|y)\big) \\
&= (1-w)\boldsymbol{u}_t^{\text{target}}(x) + w \boldsymbol{u}_t^{\text{target}}(x|y).
\end{aligned}$$

由此，经过缩放增强后的引导向量场 $\tilde{\boldsymbol{u}}_t(x|y)$ 可以写成**无条件向量场**与**引导向量场**的线性组合。直观思路：同时训练无条件向量场 $\boldsymbol{u}_t^{\text{target}}(x)$（例如使用式 (26)）与引导向量场 $\boldsymbol{u}_t^{\text{target}}(x|y)$（例如使用式 (58)），推理阶段将二者组合得到 $\tilde{\boldsymbol{u}}_t(x|y)$。

下面的交互图把这两种写法放在同一个三簇二维玩具上做数值对照（本文补充）：一条路线按式 (62)，用分类器梯度 $a_t \nabla \log p_t(y|x)$ 构造；另一条路线直接取 $(1-w)\boldsymbol{u}_t^{\text{target}}(x) + w\boldsymbol{u}_t^{\text{target}}(x|y)$。拖动 w、t 与位置，两路线的结果始终一致（二者是同一对向量场 u(x)、u(x|y) 的两种代数组合，检验的正是 u(x|y) − u(x) = $a_t \nabla \log p_t(y|x)$）。



◉ y = 1　○ y = 2　○ y = 3

量	值（二维向量）
灰：u(x)	(0.337, -0.367)
蓝：u(x|y)	(-1.016, 2.674)
绿：w·(u(x|y) − u(x))	(-2.706, 6.082)
路线一：式 (62)	(-2.369, 5.715)
路线二：CFG（红）	(-2.369, 5.715)
两路线之差	< 1e-12

p(y|x) = 0.198；a_t = 1.500

引导权重 w = **2.0**

时间 t = **0.40**

位置 x_1 = **0.70**

位置 x_2 = **-0.10**

图例：灰色实线为 u(x)，蓝色实线为 u(x|y)，绿色虚线为 w·(u(x|y) − u(x))，红色粗线为增强向量场。圆圈为 t 时刻三个簇的分布（半径 $2s_t$，圆心 $t\cdot\mu_k$，其中 $s_t^2 = t^2\sigma^2 + (1-t)^2$，σ = 0.35），实线圆是当前提示词 y 对应的簇；点击图面也可以移动位置 x。箭头长度统一按 0.32 倍显示（随 w 自动缩放，位置靠近边缘时箭头仍可能被画框裁掉），读数是真实值。路线一用后验类别概率的梯度 ∇log p(y|x) 乘以 $w\cdot a_t$ 再加到 u(x) 上；路线二直接取 (1−w)·u(x) + w·u(x|y)。两条路线的差只剩浮点误差（低于 1e-12）。

✦ 交互图 A · 分类器引导式 (62) 与 CFG 的数值对照（三簇二维玩具，$\alpha_t = t$，$\beta_t = 1 - t$，σ = 0.35）。选择提示词 y，拖动 w、t 与位置 x：画出 u(x)、u(x|y)、w·(u(x|y) − u(x))，以及增强向量场。

你可能会疑惑：“等等！那不是要训练两个模型吗？”答案是：**可以在同一个模型内同时训练两者**。我们新增一个特殊标签 ∅，代表**无条件（空提示）**。然后定义：

$$\boldsymbol{u}_t^{\text{target}}(x) = \boldsymbol{u}_t^{\text{target}}(x|\emptyset)$$

这样就不需要额外独立模型来实现分类器的增强效果。这种在单个模型中同时学习条件与无条件生成、并在推理时增强条件约束的方法，就是**无分类器引导（CFG）**[18]（见图 12 示意图）。

2.4. 对任意概率路径都成立

注记 26 · 一般概率路径下的推导

构造式

$$\tilde{\boldsymbol{u}}_t(x|y) = (1-w)\boldsymbol{u}_t^{\text{target}}(x) + w\boldsymbol{u}_t^{\text{target}}(x|y) \tag{CFG}$$

对任意概率路径都成立，并不局限于高斯路径。当 $w=1$ 时，可以直接验证 $\tilde{\boldsymbol{u}}_t(x|y) = \boldsymbol{u}_t^{\text{target}}(x|y)$。我们前面用高斯路径推导，只是为了直观解释这个构造的内在逻辑，尤其是如何放大假想“分类器梯度” $\nabla \log p_t(y|x)$ 的贡献。

03. CFG 的训练、采样与启发式

3.1. 训练：以概率 η 丢弃标签

我们需要修改式 (58) 的引导条件流匹配损失，使其支持 $y=\emptyset$。难点：从 $(z,y)\sim p_{\text{data}}$ 采样时，天然不会出现 $y=\emptyset$。因此必须人工引入空条件。引入超参数 η：以概率 η，丢弃原始标签 y，替换为空条件 $\emptyset$。

最终得到 CFG 条件流匹配损失目标：

$$\mathcal{L}_{\text{CFG-CFM}}(\theta) = \mathbb{E}_{\square}\left[\left\|\boldsymbol{u}_t^\theta(x|y) - \boldsymbol{u}_t^{\text{target}}(x|z)\right\|^2\right] \tag{63}$$

其中采样空间 $\square$：

$$\square = \left\{(z,y)\sim p_{\text{data}}(z,y),\ t\sim \text{Unif}[0,1],\ x\sim p_t(\cdot|z),\ \text{以概率 } \eta \text{ 将 } y \text{ 替换为 } \emptyset\right\} \tag{64}$$

← 左右滑动查看 →

算法 5 总结了这一训练流程（原讲义以截图给出，并用红字标注了“以一定概率丢弃标签”那一行；此处重排。原讲义算法中把丢弃概率记作 p，本文与正文一致，记作 η）。

Algorithm 5 Classifier-free guidance training

输入：成对数据集 $(z, y) \sim p_{\text{data}}$，神经网络 $\boldsymbol{u}_t^\theta$

for 每个 mini-batch 的数据 **do**

从数据集中采样一个数据样本 (z, y)

采样随机时间 $t \sim \text{Unif}_{[0,1]}$

采样噪声 $\epsilon \sim \mathcal{N}(0, I_d)$ 高斯概率路径 $p_t(x|z) = \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d)$

设 $x = \alpha_t z + \beta_t \epsilon$ 推广到一般路径：$x \sim p_t(\cdot|z)$（见式 (66)(67)）

以概率 η 丢弃标签：$y \leftarrow \emptyset$ 以一定概率丢弃标签（原讲义红字批注）

计算损失 高斯路径：$\boldsymbol{u}_t^{\text{target}}(x|z) = \dot{\alpha}_t z + \dot{\beta}_t \epsilon$

$$\mathcal{L}(\theta) = \left\| \boldsymbol{u}_t^\theta(x|y) - \boldsymbol{u}_t^{\text{target}}(x|z) \right\|^2$$

对 $\mathcal{L}(\theta)$ 做梯度下降，更新模型参数 θ

end for

✦ Algorithm 5 · 无分类器引导的训练（据原讲义重排；右侧批注为原讲义对应高斯概率路径的写法，以及红字批注）。

3.2. 小结 27：流模型的无分类器引导

小结 27 · 流模型的无分类器引导

给定无条件边缘向量场 $\boldsymbol{u}_t^{\text{target}}(x|\emptyset)$、引导条件边缘向量场 $\boldsymbol{u}_t^{\text{target}}(x|y)$，以及引导尺度 $w > 1$，我们定义无分类器引导后的增强向量场 $\tilde{\boldsymbol{u}}_t(x|y)$：

$$\tilde{\boldsymbol{u}}_t(x|y) = (1-w)\boldsymbol{u}_t^{\text{target}}(x|\emptyset) + w\boldsymbol{u}_t^{\text{target}}(x|y) \tag{65}$$

我们使用同一个神经网络同时拟合 $\boldsymbol{u}_t^{\text{target}}(x|\emptyset)$ 和 $\boldsymbol{u}_t^{\text{target}}(x|y)$，此时可以采用下面的 **CFG 条件流匹配损失（CFG-CFM）**目标函数：

$$\mathcal{L}_{\text{CFG-CFM}}(\theta) = \mathbb{E}_{\square}\left[\left\|\boldsymbol{u}_t^\theta(x|y) - \boldsymbol{u}_t^{\text{target}}(x|z)\right\|^2\right] \tag{66}$$

其中采样集合 $\square$：

$$\square = \left\{(z,y)\sim p_{\text{data}}(z,y),\ t\sim \text{Unif}[0,1],\ x\sim p_t(\cdot|z),\ \text{以概率 } \eta \text{ 将 } y \text{ 替换为 } \emptyset\right\} \tag{67}$$

← 左右滑动查看 →

用通俗语言描述，$\mathcal{L}_{\text{CFG-CFM}}$ 的采样与计算流程：

1. $(z,y)\sim p_{\text{data}}(z,y)$ ▶ 从数据联合分布采样（样本，提示词）对
2. $t\sim \text{Unif}[0,1)$ ▶ 在区间 $[0,1)$ 均匀采样时间 t
3. $x\sim p_t(x|z)$ ▶ 从条件概率路径 $p_t(x|z)$ 采样带噪样本 x
4. 以概率 η，令 $y\leftarrow\emptyset$ ▶ 以概率 η 把提示词替换为空条件
5. $\mathcal{L}_{\text{CFG-CFM}}(\theta) = \left\|\boldsymbol{u}_t^\theta(x|y) - \boldsymbol{u}_t^{\text{target}}(x|z)\right\|^2$ ▶ 让网络回归拟合目标条件向量场

推理阶段的采样流程见下面的 3.3。

3.3. 推理阶段：用增强向量场采样

推理阶段：给定固定提示词 y，采样流程：

- 初始化：$X_0\sim p_{\text{init}}(x)$ ▶ 使用简单分布（例如高斯分布）初始化
- 仿真：$dX_t = \tilde{\boldsymbol{u}}_t^\theta(X_t|y)\,dt$ ▶ 从 $t=0$ 到 $t=1$ 仿真 ODE
- 输出样本：X_1 ▶ 目标：X_1 符合引导条件 y

算法 8 总结了该采样流程（原讲义以截图给出，此处重排）：

Algorithm 8 Classifier-Free Guidance Sampling Procedure

输入：训练好的引导向量场 $\boldsymbol{u}_t^{\theta}(x|y)$，增强后记作 $\boldsymbol{u}_t^{\theta,w}(x) = (1-w)\boldsymbol{u}_t^{\theta}(x|\emptyset) + w\boldsymbol{u}_t^{\theta}(x|y)$

选取一个提示词 $y \in \mathcal{Y}$，或取 $y = \emptyset$ 做无引导采样

选取**引导尺度（guidance scale）** $w > 1$

初始化 $X_0 \sim p_{\text{init}}$

从 $t = 0$ 到 $t = 1$ 仿真

$$\mathrm{d}X_t = \left[(1-w)\,\boldsymbol{u}_t^{\theta}(X_t|\emptyset) + w\,\boldsymbol{u}_t^{\theta}(X_t|y)\right]\mathrm{d}t$$

✦ Algorithm 8 · 无分类器引导的采样流程（据原讲义重排；原讲义以红字强调 guidance scale 与增强项）。

3.4. CFG 是启发式方法

注意：当使用 $w > 1$ 时，X_1 的分布不再严格等于 $p_{\text{data}}(\cdot|y)$。但实验上，该操作能显著提升样本与条件提示的对齐程度。因此无分类器引导本质上是一种**启发式方法**，其价值主要来自极佳的实验效果。事实上，几乎所有你见到的 AI 生成图像、视频，都大量依赖无分类器引导，通常取 $w \geq 4$。Stable Diffusion 用的是 $w = 4$。

图 11 展示了在 128×128 ImageNet 上基于类别标签的无分类器引导（参考文献 [18]）。类似地，图 13 可视化了在手写数字 MNIST 数据集上做采样时，不同引导尺度 w 带来的效果变化。

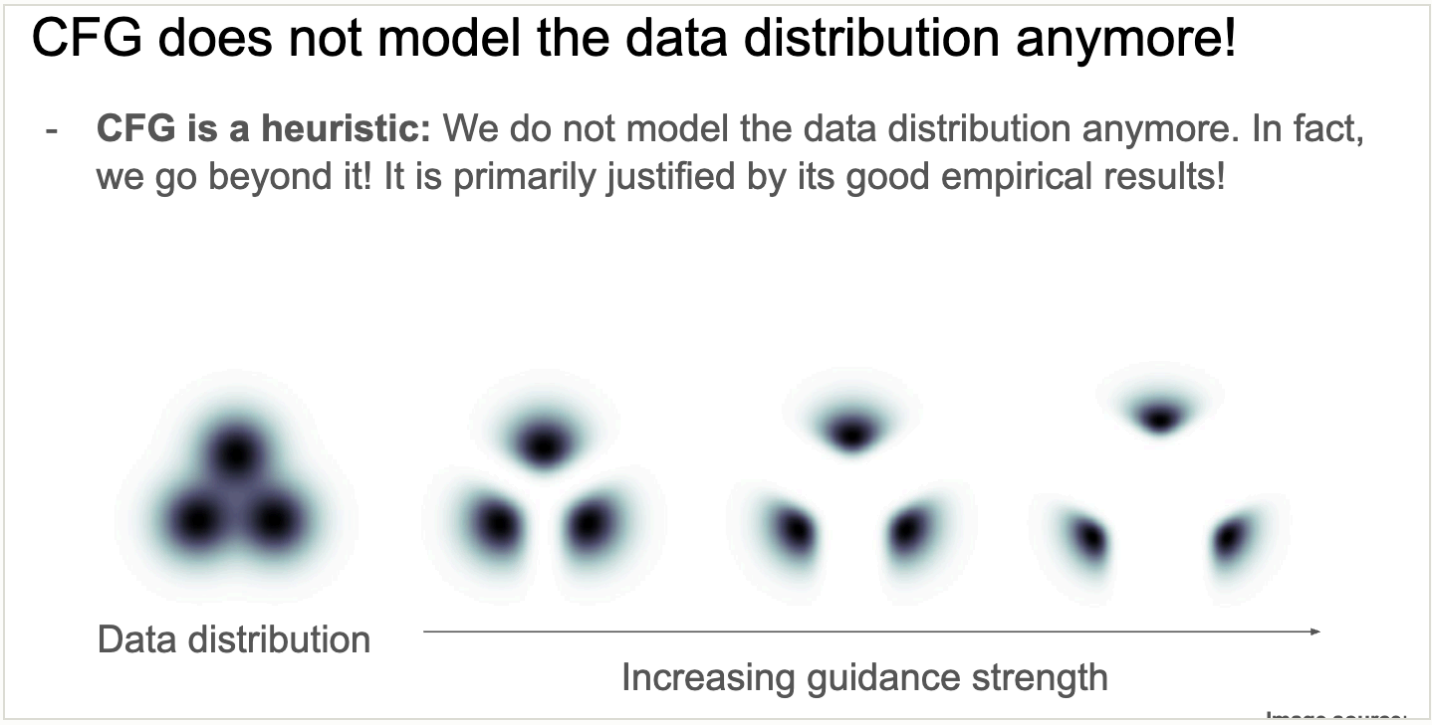


Figure 13: The effect of classifier-free guidance applied at various guidance scales for the MNIST dataset of handwritten digits. Left: Guidance scale set to $w = 1.0$. Middle: Guidance scale set to $w = 2.0$. Right: Guidance scale set to $w = 4.0$. You will generate a similar image yourself in the lab three!

图 13. 无分类器引导在 MNIST 手写数字上，不同引导尺度 w 的效果。左：w = 1.0；中：w = 2.0；右：w = 4.0。你会在 lab three 里自己生成类似的图像。 · 来源：MIT 6.S184 讲义

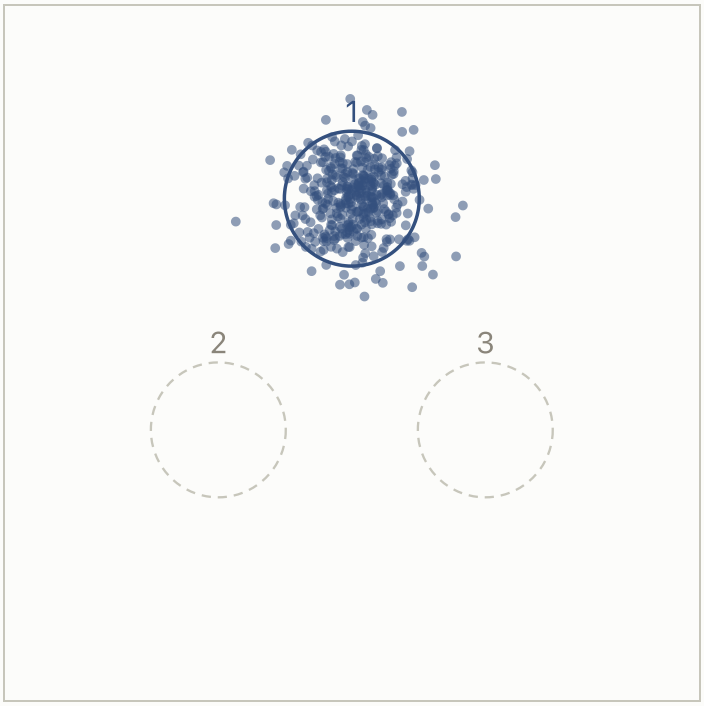
注记 28 · 扩散模型的引导

将上述讨论从流模型拓展到扩散模型是十分直接的：只需把 $\boldsymbol{u}_t^\theta(x|y)$ 替换为增强后的引导向量场 $\tilde{\boldsymbol{u}}_t^\theta(x|y)$，然后采用前几讲第 4 节介绍的 SDE 进行采样即可。

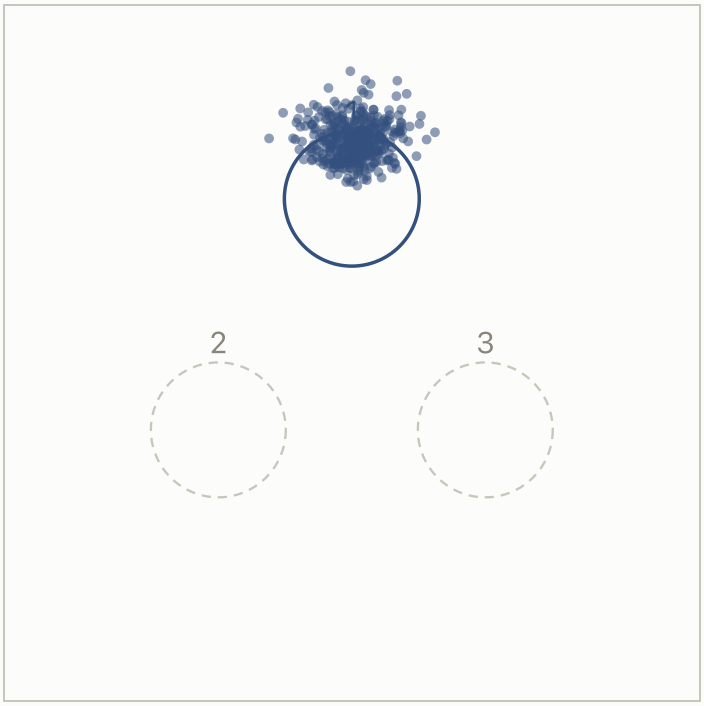


讲义幻灯片：CFG 不再建模数据分布。CFG 是一种启发式：我们不再建模数据分布，事实上还超出了它，其价值主要来自良好的实验结果。引导强度增大时，各簇被推离、变形。 · 来源：MIT 6.S184 讲义

上面幻灯片是示意图。下面的交互图用同一个三簇二维玩具真正积分一遍 CFG 的 ODE，让你自己拖 w 看样本分布如何偏离 $p_{\text{data}}(\cdot|y)$（本文补充，所有向量场由前几讲的式 (18) 精确给出，不含神经网络）。



w = 1（即数据条件分布）



w = 4.0

在 t = 1.00 的 400 个粒子	w = 1	w = 4.0
落入目标簇（距离 < 2σ）	86.8%	60.5%
到目标簇中心的平均距离	0.440	0.658
均值相对目标簇中心的偏移	(0.04, 0.00)	(0.03, 0.61)

◉ y = 1 ○ y = 2 ○ y = 3

引导权重 w = **4.0**

时间 t = **1.00**

图例：实线圆为当前提示词 y 对应簇的 2σ 范围（σ = 0.35），虚线圆为另外两个簇。两张图用同一批 400 个初始噪声 $X_0 \sim N(0, I)$，按 CFG 向量场 $(1-w)\cdot u(x|\varnothing) + w\cdot u(x|y)$ 用 Heun 法积分 200 步（u 由式 (18) 精确给出，不含神经网络）。拖到 t = 1 看最终样本；w = 1 时样本就是数据的条件分布；w 增大后，看右下表的“均值相对目标簇中心的偏移”：样本均值会离开簇中心，朝远离另外两个簇的方向偏移。

✦ 交互图 B · 引导权重 w 对 CFG 采样分布的影响（三簇二维玩具，$\alpha_t = t$，$\beta_t = 1 - t$，$\sigma = 0.35$）。左：w = 1，即数据的条件分布；右：滑块 w。拖动 t 观察 400 个粒子从高斯噪声到最终样本的演化。

结语：基础引导、分类器引导与 CFG 对照

下表把正文中散落的事实并排放在一起：

表 1. 三种引导构造的对照

构造	采样用的向量场	需要训练什么
基础引导（第 01 节）	$\boldsymbol{u}_t^\theta(x\|y)$，训练与推理都输入 y	一个网络，损失为式 (58)；理论上采样 $p_{\text{data}}(\cdot\|y)$，但实验里与提示词匹配不理想
分类器引导	$\tilde{\boldsymbol{u}}_t(x\|y) = \boldsymbol{u}_t^{\text{target}}(x) + w\, a_t \nabla \log p_t(y\|x)$（式 (62)）	两个网络：向量场加一个带噪数据上的分类器 $\log p_t(y\|x)$；y 高维时分类器很难学；$w \neq 1$ 时不再是真实的条件目标向量场
无分类器引导（CFG）	$\tilde{\boldsymbol{u}}_t(x\|y) = (1-w)\boldsymbol{u}_t^{\text{target}}(x\|\emptyset) + w\boldsymbol{u}_t^{\text{target}}(x\|y)$（式 (65)）	一个网络，同时拟合有、无提示词两种向量场；损失为式 (66)，训练时以概率 η 把 y 换成 $\emptyset$；理论上与分类器引导等价，$w > 1$ 时是启发式，常取 $w \geq 4$

从表中可以看出：CFG 用一个网络同时学条件与无条件向量场，推理时把二者之差放大 w 倍；对扩散模型，只需把增强后的向量场代入前几讲第 4 节的 SDE 即可（注记 28）。